

Autorzy:

- Paweł Moćko
- Katarzyna Wesołowska

Grupa: 5

1. Pierwsze poznanie tabeli events - 1 pkt

Zapoznaj się z tabelą events w obu bazach.

- sprawdź strukturę tabeli,
- wyświetl kilka przykładowych rekordów,
- policz liczbę wierszy,
- wyznacz minimalny i maksymalny czas zdarzenia,
- sprawdź, czy w kolumnach price i quantity występują wartości NULL, jeśli występują, wskaż ich liczbę.

Zapytania startowe:

```
SELECT
count(*) AS n,
min(event_time) AS min_time,
max(event_time) AS max_time
FROM events;
```

```
SELECT
count(*) AS all_rows,
count(price) AS non_null_price,
count(quantity) AS non_null_quantity,
count(*) - count(price) AS null_price_rows,
count(*) - count(quantity) AS null_quantity_rows
FROM events;
```

W komentarzu napisz: czy liczba rekordów i zakres czasu są zgodne w obu bazach, czy w danych występują NULL-e.

Dla obu zapytań liczba rekordów jest taka sama. Dodatkowo nie występują też jakiegokolwiek NULL-e.

2. Profil danych zdarzeniowych - 1 pkt

Przygotuj podstawowy profil danych.

- sprawdź, jakie typy zdarzeń występują w danych i ile ich jest,
- sprawdź, jakie kraje występują w danych i ile mają zdarzeń,
- sprawdź, jakie urządzenia występują w danych i ile mają zdarzeń,
- dla każdego z tych trzech przekrojów wskaż kategorię dominującą

Zapytanie startowe:

```
SELECT
event_type,
count(*) AS n
FROM events
GROUP BY event_type
ORDER BY n DESC
```

Typy zdarzeń w bazie danych

event_type	n
view	799261
add_to_cart	150406
purchase	50333

Kraje w bazie danych

```
SELECT country, COUNT(event_type)
FROM events
GROUP BY country;
```

country	COUNT(event_type)
PL	99954
NO	99972
FR	100290
US	100193
NL	100061
DE	100220
ES	100022
GB	99893
IT	99734
SE	99661

Liczba zdarzeń wg urządzeń

```
SELECT device, COUNT(event_type)
FROM events
GROUP BY device;
```

device	COUNT(event_type)
tablet	332881
desktop	333355
mobile	333764

Czyli kategorią dominującą dla każdego z trzech zestawień są kolejno:

- view
- PL
- tablet

Każde zapytanie zostało uruchomione zarówno w PostgreSQL, jak i Clickhouse. W ramach testu, sprawdzono jego czas wykonania, dla czterech wykonań. Podajemy średni czas wykonania, pomijając pierwsze wykoannie.

Nr zapytania	Baza danych	Czas [ms]
1	PostgreSQL	159

Nr zapytania	Baza danych	Czas [ms]
1	Clickhouse	15.66
2	PostgreSQL	168.33
2	Clickhouse	14.66
3	PostgreSQL	162.66
3	Clickhouse	16.33

Wnioski:

- Zapytania SQL dla PostgreSQL oraz Clickhouse wyglądały identycznie
- Identyczny nie był ich czas wykonania - czas wykonania był zdecydowanie mniejszy dla Clickhouse
- Przechowywanie danych z podziałem na kolumny - zamiast na wiersze - pozwala na zaoszczędzenie czasu dla tego typu zapytań.

3. Aktywność w czasie - 1 pkt

Sprawdź, jak zmienia się liczba zdarzeń w czasie.

1. policz liczbę zdarzeń dla kolejnych dni,

```
SELECT toDate(event_time), count(event_type) AS event_count
FROM events
GROUP BY toDate(event_time)
```

2. wskaż 5 dni o największej liczbie zdarzeń,

```
SELECT toDate(event_time), count(event_type) AS event_count
FROM events
GROUP BY toDate(event_time)
ORDER BY event_count DESC
LIMIT 5;
```

3. wskaż 5 dni o najmniejszej liczbie zdarzeń,

```
SELECT toDate(event_time), count(event_type) AS event_count
FROM events
GROUP BY toDate(event_time)
ORDER BY event_count
LIMIT 5;
```

Powyższe zapytania są dla bazy danych Clickhouse. Dla PostgreSQL należy zamienić wywołania funkcji `toDate` funkcją `DATE`.

Poniżej wklejam dane dla dni z największą liczbą zdarzeń:

toDate(event_time)	event_count
2025-02-21	5727
2025-02-04	5703
2025-02-24	5693
2025-04-23	5693

toDate(event_time)	event_count
2025-02-20	5691

oraz z najmniejszą:

toDate(event_time)	event_count
2025-05-01	5315
2025-01-11	5342
2025-01-29	5382
2025-02-02	5397
2025-03-23	5407

Na podstawie powyższych wyników (oraz wizualnej inspekcji wyników 1. zapytania) - wnioskujemy, że rozkład liczby zdarzeń wg daty wygląda na równomiernie rozłożony. Dla powyższych zapytań, ponownie zaobserwowaliśmy znacznie szybszy czas wykonania dla Clickhouse (o rząd wielkości).

4. Podstawowe KPI sprzedażowe - 2pkt

Zapytanie, które zwraca:

- liczbę zdarzeń typu *purchase*
- łączny przychód ze zdarzeń typu *purchase*
- średnią wartość pojedynczego zakupu
- średnią liczbę sztuk w pojedynczym zakupie
- liczbę sesji, w których wystąpił zakup
- uproszczony wskaźnik konwersji ma postać:

```
SELECT count(*) AS purchases_cnt,
       sum(price * quantity) AS revenue,
       avg(price * quantity) AS avg_order_value,
       avg(quantity) AS avg_quantity,
       count(DISTINCT session_id) AS session_cnt,
       count(DISTINCT session_id) / count(session_id) AS conversion_rate
FROM events
WHERE event_type = 'purchase';
```

Dodatkowo przeprowadziliśmy analizę czasów wykonania dla obu baz danych. Średni czas wykonania dla Clickhouse wynosił 17.66 ms, dla PostgreSQL 93 ms. Zatem przewaga Clickhouse zmalała dla powyższego. Same wyniki w obu bazach są spójne.

dlaczego udział sesji zakupowych lepiej opisuje konwersję niż prosty stosunek liczby zdarzeń purchase do liczby zdarzeń view.

Liczba zdarzeń typu *view* może być powiększana przez zdarzenia niezwiązane z chęcią kupna, na przykład odświeżenie zakładki przeglądarki, lub ponowne wrócenie do oferty z arbitralnych powodów. Podział na sesję pozwala lepiej zobrazować jaki procent wyświetlenia pewnego produktu rzeczywiście kończy się jego kupnem.

5. KPI w przekrojach biznesowych - 1 pkt

Najpierw przedstawiamy przekrój wg kraju:

```
SELECT country, sum(price * quantity) AS revenue
FROM events
WHERE event_type = 'purchase'
```

```
GROUP BY country
ORDER BY revenue DESC;
```

country	revenue
FR	1805210.3199999991
IT	1779036.9599999995
PL	1774036.4399999997
NL	1753906.4699999993
SE	1749563.0100000019
GB	1748815.37
NO	1733380.0399999998
ES	1707084.7800000005
US	1703552.5700000003
DE	1694584.4000000008

Największy dochód otrzymujemy dla Francji. Analogiczn zapytanie z przekrojem wg urządzenia

```
SELECT device, sum(price * quantity) AS revenue
FROM events
WHERE event_type = 'purchase'
GROUP BY device
ORDER BY revenue DESC;
```

Wyniki:

device	revenue
tablet	5838853.9800000003
desktop	5835272.0900000004
mobile	5775044.2899999999

Okazuje się, że przy podziale wg państw oraz urządzeń, otrzymujemy porównywalny przychód. Dodatkowo dokonaliśmy analizy czasu wykonania dla obu zapytań:

Nr zapytania	Baza danych	Czas wykonania [ms]
1	Clickhouse	16.66
1	PostgreSQL	82
2	Clickhouse	20.33
2	PostgreSQL	83.66

Znowu - czasy wykonania dla Clickhouse są znacznie mniejsze.

6. Użytkownicy o najwyższym przychodzie - 1 pkt

Znajdź użytkowników o najwyższym łącznym przychodzie z zakupów. Wynik powinien zawierać: user_id, liczbę wszystkich zdarzeń użytkownika, liczbę zdarzeń typu purchase, łączny przychód użytkownika ze zdarzeń typu purchase. Pokaż co najmniej 20 rekordów o najwyższym przychodzie. Ważne: Przychód licz tylko dla zdarzeń typu purchase. Wskazówka: W tym zadaniu przydatne może być warunkowe zliczanie i warunkowe sumowanie.

W komentarzu napisz: • czy użytkownik z najwyższym przychodem ma też największą liczbę wszystkich zdarzeń, • czy duża aktywność użytkownika zawsze oznacza wysoki przychód, • jakie wnioski można wyciągnąć z porównania liczby zdarzeń i przychodu.

Odpowiedź:

Postgresql

```
SELECT
  user_id,
  count(*) AS all_events,
  count(CASE WHEN event_type = 'purchase' THEN 1 END) AS purchase_events,
  sum(CASE
    WHEN event_type = 'purchase' THEN price * quantity
    ELSE 0
  END) AS revenue
FROM events
GROUP BY user_id
ORDER BY revenue DESC
LIMIT 20;
```

Wyniki:

user_id	all_events	purchase_events	revenue
21194	25	4	5037.99
11919	23	3	4859.679999999999
18860	27	3	4639.92
21978	26	3	4604.17
39652	27	3	4584.65
35735	29	5	4527.26
32592	24	4	4526.1
48742	21	5	4460.98
4935	26	4	4360.120000000001
9978	24	3	4301.87
33799	22	2	4204.8
29614	26	7	4192.2
36059	18	4	4160.820000000001
7178	25	4	4119.37
37756	25	5	4078.35
23725	23	3	4006.1099999999997
7009	22	3	4001.56
3112	24	4	3980.3599999999997
47934	27	4	3915.71
48299	32	3	3866.2

ClickHouse:

```

SELECT
    user_id,
    count() AS all_events,
    countIf(event_type = 'purchase') AS purchase_events,
    sumIf(price * quantity, event_type = 'purchase') AS revenue
FROM events
GROUP BY user_id
ORDER BY revenue DESC
LIMIT 20;

```

Wyniki:

user_id	all_events	purchase_events	revenue
21194	25	4	5037.99
11919	23	3	4859.679999999999
18860	27	3	4639.92
21978	26	3	4604.17
39652	27	3	4584.65
35735	29	5	4527.26
32592	24	4	4526.099999999999
48742	21	5	4460.98
4935	26	4	4360.120000000001
9978	24	3	4301.870000000001
33799	22	2	4204.8
29614	26	7	4192.2
36059	18	4	4160.82
7178	25	4	4119.37
37756	25	5	4078.350000000004
23725	23	3	4006.11
7009	22	3	4001.56
3112	24	4	3980.3599999999997
47934	27	4	3915.71
48299	32	3	3866.2000000000003

Komentarz:

- Różnice, które widać w wynikach z obu baz danych wynikają tylko z zapisu liczb zmiennoprzecinkowych (zaokrągleń).
- Użytkownik z najwyższym przychodem nie ma największej liczby wszystkich zdarzeń. W tabeli wynikowej widać, że osoba z najwyższym przychodem ma 25 zdarzeń, a w pokazanym top 20 widać jeszcze użytkownika z 32 zdarzeniami.
- Duża aktywność użytkownika nie zawsze oznacza wysoki przychód. Może oznaczać częste przeglądanie lub inne akcje, ale nie musi oznaczać dużych zakupów.
- Z porównania liczby zdarzeń i przychodu można wyciągnąć wnioski, że sama aktywność użytkownika nie wystarcza do oceny jego wartości. Ważniejsze jest to, ile użytkownik ma zakupów i jaką mają one wartość.

7. Benchmark zapytań w PostgreSQL i ClickHouse - 3 pkt

Odpowiedź:

Wyniki część A1:

Postgresql:

```
SELECT
    count(*) AS purchases_cnt,
    sum(price * quantity) AS revenue,
    avg(price * quantity) AS avg_order_value,
    avg(quantity) AS avg_quantity
FROM events
WHERE event_type = 'purchase';
```

Wynik:

purchases_cnt	revenue	avg_order_value	avg_quantity
50,333	17,449,170.36	346.67	1.38

ClickHouse:

```
SELECT
    count() AS purchases_cnt,
    sum(price * quantity) AS revenue,
    avg(price * quantity) AS avg_order_value,
    avg(quantity) AS avg_quantity
FROM events
WHERE event_type = 'purchase';
```

Wynik:

purchases_cnt	revenue	avg_order_value	avg_quantity
50,333	17,449,170.36	346.67	1.38

Wyniki część A2:

Postgresql:

```
SELECT
    user_id,
    count(*) AS all_events,
    count(CASE WHEN event_type = 'purchase' THEN 1 END) AS purchase_events,
    sum(CASE
        WHEN event_type = 'purchase' THEN price * quantity
        ELSE 0
    END) AS revenue
FROM events
GROUP BY user_id
ORDER BY revenue DESC
LIMIT 20;
```

Wynik:

user_id	all_events	purchase_events	revenue
21194	25	4	5,037.99
11919	23	3	4,859.68
18860	27	3	4,639.92
21978	26	3	4,604.17
39652	27	3	4,584.65
35735	29	5	4,527.26
32592	24	4	4,526.10
48742	21	5	4,460.98
4935	26	4	4,360.12
9978	24	3	4,301.87
33799	22	2	4,204.80
29614	26	7	4,192.20
36059	18	4	4,160.82
7178	25	4	4,119.37
37756	25	5	4,078.35
23725	23	3	4,006.11
7009	22	3	4,001.56
3112	24	4	3,980.36
47934	27	4	3,915.71
48299	32	3	3,866.20

ClickHouse:

```
SELECT
  user_id,
  count() AS all_events,
  countIf(event_type = 'purchase') AS purchase_events,
  sumIf(price * quantity, event_type = 'purchase') AS revenue
FROM events
GROUP BY user_id
ORDER BY revenue DESC
LIMIT 20;
```

Wynik:

user_id	all_events	purchase_events	revenue
21,194	25	4	5,037.99
11,919	23	3	4,859.68
18,860	27	3	4,639.92
21,978	26	3	4,604.17
39,652	27	3	4,584.65

user_id	all_events	purchase_events	revenue
35,735	29	5	4,527.26
32,592	24	4	4,526.10
48,742	21	5	4,460.98
4,935	26	4	4,360.12
9,978	24	3	4,301.87
33,799	22	2	4,204.80
29,614	26	7	4,192.20
36,059	18	4	4,160.82
7,178	25	4	4,119.37
37,756	25	5	4,078.35
23,725	23	3	4,006.11
7,009	22	3	4,001.56
3,112	24	4	3,980.36
47,934	27	4	3,915.71
48,299	32	3	3,866.20

Wyniki część B:

Postgresql:

```
SELECT
    DATE(event_time) AS day,
    country,
    device,
    event_type,
    count(*) AS events_cnt,
    count(DISTINCT user_id) AS users_cnt,
    count(DISTINCT session_id) AS sessions_cnt,
    sum(CASE
        WHEN event_type = 'purchase' THEN price * quantity
        ELSE 0
    END) AS revenue
FROM events
GROUP BY
    DATE(event_time),
    country,
    device,
    event_type
ORDER BY revenue DESC
LIMIT 20;
```

Wynik:

day	country	device	event_type	events_cnt	users_cnt	sessions_cnt	revenue
2025-06-13	US	mobile	purchase	14	14	14	10,827.56
2025-04-21	US	tablet	purchase	21	21	21	9,945.94
2025-01-23	IT	tablet	purchase	19	19	19	9,584.16

day	country	device	event_type	events_cnt	users_cnt	sessions_cnt	revenue
2025-05-15	IT	desktop	purchase	15	15	15	9,468.63
2025-05-30	DE	desktop	purchase	18	18	18	9,445.29
2025-03-04	US	tablet	purchase	18	18	18	9,403.07
2025-01-04	GB	tablet	purchase	20	20	20	9,342.12
2025-02-04	FR	tablet	purchase	21	21	21	9,139.39
2025-02-24	IT	desktop	purchase	16	16	16	9,022.18
2025-04-19	PL	mobile	purchase	15	15	15	8,954.64
2025-05-25	DE	mobile	purchase	15	15	15	8,909.98
2025-06-10	DE	desktop	purchase	21	21	21	8,884.72
2025-03-24	IT	desktop	purchase	17	17	17	8,801.78
2025-03-20	IT	desktop	purchase	11	11	11	8,796.71
2025-05-10	IT	tablet	purchase	15	15	15	8,755.74
2025-04-19	ES	mobile	purchase	13	13	13	8,738.15
2025-06-14	PL	tablet	purchase	14	14	14	8,689.47
2025-04-26	US	tablet	purchase	14	14	14	8,663.77
2025-03-25	SE	mobile	purchase	15	15	15	8,570.77
2025-04-18	FR	mobile	purchase	13	13	13	8,570.72

ClickHouse:

```
SELECT
    toDate(event_time) AS day,
    country,
    device,
    event_type,
    count() AS events_cnt,
    count(DISTINCT user_id) AS users_cnt,
    count(DISTINCT session_id) AS sessions_cnt,
    sum(CASE
        WHEN event_type = 'purchase' THEN price * quantity
        ELSE 0
    END) AS revenue
FROM events
GROUP BY
    day,
    country,
    device,
    event_type
ORDER BY revenue DESC
LIMIT 20;
```

Wynik:

day	country	device	event_type	events_cnt	users_cnt	sessions_cnt	revenue
2025-06-13	US	mobile	purchase	14	14	14	10,827.56
2025-04-21	US	tablet	purchase	21	21	21	9,945.94

day	country	device	event_type	events_cnt	users_cnt	sessions_cnt	revenue
2025-01-23	IT	tablet	purchase	19	19	19	9,584.16
2025-05-15	IT	desktop	purchase	15	15	15	9,468.63
2025-05-30	DE	desktop	purchase	18	18	18	9,445.29
2025-03-04	US	tablet	purchase	18	18	18	9,403.07
2025-01-04	GB	tablet	purchase	20	20	20	9,342.12
2025-02-04	FR	tablet	purchase	21	21	21	9,139.39
2025-02-24	IT	desktop	purchase	16	16	16	9,022.18
2025-04-19	PL	mobile	purchase	15	15	15	8,954.64
2025-05-25	DE	mobile	purchase	15	15	15	8,909.98
2025-06-10	DE	desktop	purchase	21	21	21	8,884.72
2025-03-24	IT	desktop	purchase	17	17	17	8,801.78
2025-03-20	IT	desktop	purchase	11	11	11	8,796.71
2025-05-10	IT	tablet	purchase	15	15	15	8,755.74
2025-04-19	ES	mobile	purchase	13	13	13	8,738.15
2025-06-14	PL	tablet	purchase	14	14	14	8,689.47
2025-04-26	US	tablet	purchase	14	14	14	8,663.77
2025-03-25	SE	mobile	purchase	15	15	15	8,570.77
2025-04-18	FR	mobile	purchase	13	13	13	8,570.72

Wyniki część C:

Zmodyfikowane polecenie z części B - tylko 'purchase', bez grupowania według 'event_type'

Postgresql:

```
SELECT
    DATE(event_time) AS day,
    country,
    device,
    count(*) AS purchases_cnt,
    count(DISTINCT user_id) AS users_cnt,
    count(DISTINCT session_id) AS sessions_cnt,
    sum(price * quantity) AS revenue
FROM events
WHERE event_type = 'purchase'
GROUP BY
    DATE(event_time),
    country,
    device
ORDER BY revenue DESC
LIMIT 20;
```

Wynik:

day	country	device	purchases_cnt	users_cnt	sessions_cnt	revenue
2025-06-13	US	mobile	14	14	14	10,827.56

day	country	device	purchases_cnt	users_cnt	sessions_cnt	revenue
2025-04-21	US	tablet	21	21	21	9,945.94
2025-01-23	IT	tablet	19	19	19	9,584.16
2025-05-15	IT	desktop	15	15	15	9,468.63
2025-05-30	DE	desktop	18	18	18	9,445.29
2025-03-04	US	tablet	18	18	18	9,403.07
2025-01-04	GB	tablet	20	20	20	9,342.12
2025-02-04	FR	tablet	21	21	21	9,139.39
2025-02-24	IT	desktop	16	16	16	9,022.18
2025-04-19	PL	mobile	15	15	15	8,954.64
2025-05-25	DE	mobile	15	15	15	8,909.98
2025-06-10	DE	desktop	21	21	21	8,884.72
2025-03-24	IT	desktop	17	17	17	8,801.78
2025-03-20	IT	desktop	11	11	11	8,796.71
2025-05-10	IT	tablet	15	15	15	8,755.74
2025-04-19	ES	mobile	13	13	13	8,738.15
2025-06-14	PL	tablet	14	14	14	8,689.47
2025-04-26	US	tablet	14	14	14	8,663.77
2025-03-25	SE	mobile	15	15	15	8,570.77
2025-04-18	FR	mobile	13	13	13	8,570.72

ClickHouse:

```
SELECT
  toDate(event_time) AS day,
  country,
  device,
  count() AS purchases_cnt,
  count(DISTINCT user_id) AS users_cnt,
  count(DISTINCT session_id) AS sessions_cnt,
  sum(price * quantity) AS revenue
FROM events
WHERE event_type = 'purchase'
GROUP BY
  day,
  country,
  device
ORDER BY revenue DESC
LIMIT 20;
```

Wynik:

day	country	device	purchases_cnt	users_cnt	sessions_cnt	revenue
2025-06-13	US	mobile	14	14	14	10,827.56
2025-04-21	US	tablet	21	21	21	9,945.94

day	country	device	purchases_cnt	users_cnt	sessions_cnt	revenue
2025-01-23	IT	tablet	19	19	19	9,584.16
2025-05-15	IT	desktop	15	15	15	9,468.63
2025-05-30	DE	desktop	18	18	18	9,445.29
2025-03-04	US	tablet	18	18	18	9,403.07
2025-01-04	GB	tablet	20	20	20	9,342.12
2025-02-04	FR	tablet	21	21	21	9,139.39
2025-02-24	IT	desktop	16	16	16	9,022.18
2025-04-19	PL	mobile	15	15	15	8,954.64
2025-05-25	DE	mobile	15	15	15	8,909.98
2025-06-10	DE	desktop	21	21	21	8,884.72
2025-03-24	IT	desktop	17	17	17	8,801.78
2025-03-20	IT	desktop	11	11	11	8,796.71
2025-05-10	IT	tablet	15	15	15	8,755.74
2025-04-19	ES	mobile	13	13	13	8,738.15
2025-06-14	PL	tablet	14	14	14	8,689.47
2025-04-26	US	tablet	14	14	14	8,663.77
2025-03-25	SE	mobile	15	15	15	8,570.77
2025-04-18	FR	mobile	13	13	13	8,570.72

Zapytanie	PostgreSQL - pomiar 1	PostgreSQL - pomiar 2	PostgreSQL - pomiar 3	PostgreSQL - średnia	ClickHouse - pomiar 1	ClickHouse - pomiar 2	ClickHouse - pomiar 3	ClickHouse - średnia
A1	0,544s	0,252s	0,531s	0,442s	0,075s	0,025s	0,315s	0,138s
A2	2,671s	1,311s	1,094s	1,692s	0,226s	0,165s	0,155s	0,182s
B	8,082s	6,968s	7,438s	7,496s	0,45s	0,301s	0,394s	0,382s
C	0,537s	0,823s	0,549s	0,636s	0,117s	0,423s	0,274s	0,271s

Komentarz:

- Wyniki były zgodne w PostgreSQL i ClickHouse.
- Różnice czasu wykonania były widoczne. ClickHouse był szybszy.
- Największa różnica pojawiła się przy najbardziej złożonym zapytaniu B, ponieważ zawierał on agregacje z grupowaniem i liczeniem wartości DISTINCT.
- Na podstawie tego ćwiczenia można wstępnie stwierdzić, że bardziej złożone agregacje są naturalnym zastosowaniem systemu analitycznego takiego jak ClickHouse.