

Sprawozdanie_1_Wesołowska

Katarzyna Wesołowska

2026-04-13

Miary i statystyki użyte w sprawozdaniu

W tej sekcji zdefiniowano miary i statystyki wykorzystywane w dalszej części sprawozdania.

Współczynnik korelacji Pearsona

Współczynnik korelacji Pearsona mierzy siłę i kierunek liniowej zależności między dwiema zmiennymi:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Wartości bliskie 1 oznaczają silną korelację dodatnią, bliskie -1 silną korelację ujemną, a bliskie 0 brak liniowej zależności.

Współczynnik determinacji R^2

Współczynnik determinacji określa, jaka część zmienności zmiennej zależnej jest wyjaśniana przez model:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Im większa wartość R^2 , tym lepsze dopasowanie modelu do danych.

Skorygowany współczynnik determinacji

Skorygowany współczynnik determinacji uwzględnia liczbę zmiennych objaśniających w modelu:

$$R_{adj}^2 = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1}$$

gdzie n oznacza liczbę obserwacji, a p liczbę zmiennych objaśniających.

AIC

Kryterium informacyjne Akaikego służy do porównywania modeli:

$$AIC = 2k - 2 \ln(L)$$

gdzie k oznacza liczbę parametrów modelu, a L wartość funkcji wiarygodności. Mniejsza wartość AIC oznacza lepszy model spośród porównywanych modeli.

VIF

Wskaźnik VIF służy do oceny współliniowości zmiennych objaśniających:

$$VIF_j = \frac{1}{1 - R_j^2}$$

gdzie R_j^2 jest współczynnikiem determinacji z regresji, w której j -ta zmienna objaśniająca jest wyjaśniana przez pozostałe zmienne objaśniające. Duże wartości VIF wskazują na problem współliniowości.

Statystyka Durбина-Watsona

Test Durбина-Watsona służy do sprawdzania autokorelacji reszt:

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

gdzie e_i oznacza reszty modelu. Wartość bliska 2 sugeruje brak autokorelacji.

Statystyka Breuscha-Pagana

Test Breuscha-Pagana służy do oceny homoskedastyczności, czyli stałości wariancji reszt. Statystyka testowa ma postać:

$$BP = n \cdot R^2$$

gdzie R^2 pochodzi z regresji pomocniczej opartej na kwadratach reszt. Mała wartość p wskazuje na heteroskedastyczność.

Test Shapiro-Wilka

Test Shapiro-Wilka służy do oceny normalności rozkładu reszt. Statystyka testowa ma postać:

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Mała wartość p oznacza odrzucenie hipotezy o normalności rozkładu.

Logarytm funkcji wiarygodności

Logarytm funkcji wiarygodności dla modelu z parametrami θ ma postać:

$$\log L(\theta) = \sum_{i=1}^n \log f(y_i | \theta)$$

Większa wartość oznacza lepsze dopasowanie modelu do danych.

Dewiacja modelu

Dewiacja mierzy niedopasowanie modelu względem modelu nasyconego:

$$D = 2 [\log L(\text{model nasycony}) - \log L(\text{model dopasowany})]$$

Mniejsza wartość dewiacji oznacza lepsze dopasowanie modelu.

Null deviance i Residual deviance

Null deviance to dewiacja modelu zerowego, czyli takiego, który zawiera tylko wyraz wolny:

$$D_0 = 2 [\log L(\text{model nasycony}) - \log L(\text{model zerowy})]$$

Residual deviance to dewiacja modelu po uwzględnieniu zmiennych objaśniających:

$$D_R = 2 [\log L(\text{model nasycony}) - \log L(\text{model dopasowany})]$$

Im większy spadek z **Null deviance** do **Residual deviance**, tym większa poprawa dopasowania po dodaniu predyktorów.

Reszty dewiancyjne

Reszta dewiancyjna dla i -tej obserwacji ma postać:

$$r_i^{(D)} = \text{sign}(y_i - \hat{\mu}_i) \sqrt{d_i}$$

gdzie d_i oznacza wkład i -tej obserwacji do dewiacji. Reszty dewiancyjne powinny być w przybliżeniu symetryczne względem zera.

Statystyka z

W modelach GLM i CLM istotność pojedynczego współczynnika ocenia się często statystyką:

$$z = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

gdzie $\hat{\beta}_j$ to oszacowanie współczynnika, a $SE(\hat{\beta}_j)$ jego błąd standardowy.

Test ilorazu wiarygodności

Przy porównywaniu modeli zagnieżdżonych stosuje się statystykę:

$$LR = 2 [\log L(\text{model pełny}) - \log L(\text{model uproszczony})]$$

Statystyka ta ma w przybliżeniu rozkład χ^2 i pozwala ocenić istotność całych atrybutów w modelu.

Zadanie 1

1.1 Real Estate Valuation

Wczytanie i wstępne przygotowanie danych

```
library(tidyverse)
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.1.4      v readr      2.1.5
## v forcats    1.0.1      v stringr   1.5.2
## v ggplot2    4.0.0      v tibble    3.2.1
## v lubridate  1.9.4      v tidyr     1.3.1
## v purrr      1.2.1
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(readxl)
library(janitor)
```

```
##
## Attaching package: 'janitor'
##
## The following objects are masked from 'package:stats':
##
##   chisq.test, fisher.test
```

```
library(car)
```

```
## Loading required package: carData
##
## Attaching package: 'car'
##
## The following object is masked from 'package:dplyr':
##
##   recode
##
## The following object is masked from 'package:purrr':
##
##   some
```

```
library(lmtest)
```

```
## Loading required package: zoo
##
## Attaching package: 'zoo'
##
## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric
```

```
library(MASS)
```

```
##
## Attaching package: 'MASS'
##
## The following object is masked from 'package:dplyr':
##
##   select
```

```
library(ordinal)
```

```
##
## Attaching package: 'ordinal'
##
## The following object is masked from 'package:dplyr':
##
##   slice
```

```
#pomija ostrzezenia
knitr::opts_chunk$set(
  echo = TRUE,
  message = FALSE,
  warning = FALSE
)
```

Wczytanie danych Real Estate.

```
real_estate <- read_excel("Real estate valuation data set.xlsx") %>%
  clean_names()

names(real_estate)
```

```
## [1] "no"
## [2] "x1_transaction_date"
## [3] "x2_house_age"
## [4] "x3_distance_to_the_nearest_mrt_station"
## [5] "x4_number_of_convenience_stores"
## [6] "x5_latitude"
## [7] "x6_longitude"
## [8] "y_house_price_of_unit_area"
```

Usunięcie kolumn z numerem porządkowym, uproszczenie nazw kolumn, sprawdzenie braków danych oraz podstawowych informacji o nich.

```
real_estate <- real_estate %>%
  dplyr::select(-no)

colnames(real_estate) <- c("transaction_date", "house_age", "distance_to_mrt", "stores", "latitude", "longitude", "price")

colSums(is.na(real_estate))
```

```
## transaction_date      house_age distance_to_mrt      stores
##           0           0           0           0
##      latitude      longitude      price
##           0           0           0
```

```
str(real_estate)
```

```
## tibble [414 x 7] (S3: tbl_df/tbl/data.frame)
## $ transaction_date: num [1:414] 2013 2013 2014 2014 2013 ...
## $ house_age       : num [1:414] 32 19.5 13.3 13.3 5 7.1 34.5 20.3 31.7 17.9 ...
## $ distance_to_mrt : num [1:414] 84.9 306.6 562 562 390.6 ...
## $ stores          : num [1:414] 10 9 5 5 5 3 7 6 1 3 ...
## $ latitude        : num [1:414] 25 25 25 25 25 ...
## $ longitude        : num [1:414] 122 122 122 122 122 ...
## $ price           : num [1:414] 37.9 42.2 47.3 54.8 43.1 32.1 40.3 46.7 18.8 22.1 ...
```

```
summary(real_estate)
```

```
## transaction_date      house_age      distance_to_mrt      stores
## Min.   :2013      Min.   : 0.000      Min.   : 23.38      Min.   : 0.000
## 1st Qu.:2013      1st Qu.: 9.025      1st Qu.: 289.32      1st Qu.: 1.000
## Median :2013      Median :16.100      Median : 492.23      Median : 4.000
## Mean   :2013      Mean   :17.713      Mean   :1083.89      Mean   : 4.094
## 3rd Qu.:2013      3rd Qu.:28.150      3rd Qu.:1454.28      3rd Qu.: 6.000
## Max.   :2014      Max.   :43.800      Max.   :6488.02      Max.   :10.000
## latitude      longitude      price
## Min.   :24.93      Min.   :121.5      Min.   : 7.60
## 1st Qu.:24.96      1st Qu.:121.5      1st Qu.: 27.70
## Median :24.97      Median :121.5      Median : 38.45
## Mean   :24.97      Mean   :121.5      Mean   : 37.98
## 3rd Qu.:24.98      3rd Qu.:121.5      3rd Qu.: 46.60
## Max.   :25.01      Max.   :121.6      Max.   :117.50
```

Zbiór Real Estate po usunięciu kolumny `no` zawiera 414 obserwacji i 7 zmiennych. Wszystkie analizowane zmienne są liczbowe, więc mogą zostać użyte w modelu regresji liniowej/wielokrotnej/z interakcjami. W danych nie występują braki, ponieważ dla każdej kolumny liczba wartości NA wynosi 0. Gdyby braki danych występowały, można byłoby usunąć niekompletne obserwacje albo uzupełnić brakujące wartości, np. średnią lub medianą.


Macierz korelacji między zmiennymi objaśniającymi, wraz z wykresem rozrzutu oraz wizualizacją wartości odstających

```
cor_matrix <- cor(real_estate %>% dplyr::select(-price))
knitr::kable(round(cor_matrix, 2), caption = "Macierz korelacji - Real Estate")
```


Table 1: Macierz korelacji - Real Estate

	transaction_date	house_age	distance_to_mrt	stores	latitude	longitude
transaction_date	1.00	0.02	0.06	0.01	0.04	-0.04
house_age	0.02	1.00	0.03	0.05	0.05	-0.05
distance_to_mrt	0.06	0.03	1.00	-0.60	-0.59	-0.81
stores	0.01	0.05	-0.60	1.00	0.44	0.45
latitude	0.04	0.05	-0.59	0.44	1.00	0.41
longitude	-0.04	-0.05	-0.81	0.45	0.41	1.00

```
pairs(real_estate)
```



```
boxplot(real_estate %>% dplyr::select(-price))
```



Macierz korelacji pokazuje, że część zmiennych objaśniających jest ze sobą wyraźnie skorelowana. Najsilniejsza zależność występuje między `distance_to_mrt` i `longitude` ($r = -0.81$), a także między `distance_to_mrt` i `stores` ($r = -0.60$) oraz `distance_to_mrt` i `latitude` ($r = -0.59$). Może to wskazywać na ryzyko współliniowości.

Na wykresach rozrzutu widać, że zależności między niektórymi zmiennymi a ceną mogą być w przybliżeniu liniowe, ale pojawiają się też obserwacje nietypowe.

Boxplot wskazuje szczególnie na wartości odstające dla zmiennej `distance_to_mrt`.

Do sprawdzenia, czy zmienne są skorelowane, można użyć testu korelacji Pearsona. W dalszej analizie współliniowość w modelu regresji można dodatkowo ocenić za pomocą wskaźnika VIF.

W przypadku danych odstających można przyjąć kilka podejść: pozostawić je w zbiorze, jeśli są rzeczywistymi obserwacjami, usunąć je, jeśli są błędami pomiaru, albo porównać wyniki modelu z obserwacjami odstającymi i bez nich.

Regresja wieloraka z interakcjami

```
model_real_estate <- lm(price ~ (transaction_date + house_age +
                                distance_to_mrt + stores + latitude + longitude)^2,
                        data = real_estate)

summary(model_real_estate)
```

```
##
## Call:
```




```
## lm(formula = price ~ (transaction_date + house_age + distance_to_mrt +
##   stores + latitude + longitude)^2, data = real_estate)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -36.474  -4.329  -0.738   3.293  70.522
##
## Coefficients: (3 not defined because of singularities)
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -5.040e+04  1.724e+04  -2.923  0.00366 **
## transaction_date    6.782e+00  4.415e+00   1.536  0.12527
## house_age         3.325e+02  7.527e+02   0.442  0.65898
## distance_to_mrt    8.767e+00  4.172e+00   2.101  0.03625 *
## stores           5.422e+03  4.136e+03   1.311  0.19061
## latitude          9.939e+02  1.631e+02   6.092 2.65e-09 ***
## longitude         9.854e+01  1.178e+02   0.837  0.40329
## transaction_date:house_age    1.043e-01  1.259e-01   0.828  0.40825
## transaction_date:distance_to_mrt -8.601e-04  1.352e-03  -0.636  0.52490
## transaction_date:stores     -3.887e-01  6.074e-01  -0.640  0.52257
## transaction_date:latitude      NA         NA      NA      NA
## transaction_date:longitude     NA         NA      NA      NA
## house_age:distance_to_mrt    8.616e-06  7.877e-05   0.109  0.91295
## house_age:stores           9.448e-03  1.384e-02   0.682  0.49534
## house_age:latitude     -2.897e+00  4.374e+00  -0.662  0.50816
## house_age:longitude     -3.870e+00  5.761e+00  -0.672  0.50219
## distance_to_mrt:stores     -1.687e-03  3.852e-04  -4.378 1.53e-05 ***
## distance_to_mrt:latitude    -2.229e-01  4.396e-02  -5.072 6.08e-07 ***
## distance_to_mrt:longitude   -1.212e-02  2.702e-02  -0.449  0.65394
## stores:latitude          -1.071e+02  2.150e+01  -4.981 9.48e-07 ***
## stores:longitude         -1.616e+01  3.118e+01  -0.518  0.60460
## latitude:longitude      NA         NA      NA      NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.903 on 395 degrees of freedom
## Multiple R-squared:  0.6773, Adjusted R-squared:  0.6626
## F-statistic: 46.06 on 18 and 395 DF, p-value: < 2.2e-16
```

Na podstawie wyników modelu za istotne statystycznie zmienne i interakcje (dla $p < 0.05$) uznano: `distance_to_mrt`, `latitude`, `distance_to_mrt:stores`, `distance_to_mrt:latitude` oraz `stores:latitude`. Pozostałe zmienne i interakcje nie wykazały istotnego wpływu na model. W modelu pojawiły się również współczynniki NA, co wskazuje na problem współliniowości lub zależności liniowej między niektórymi predyktorami.

Sprawdzenie założeń regresji

Wykresy diagnostyczne modelu

```
par(mfrow = c(2, 2))
plot(model_real_estate)
```



```
par(mfrow = c(1, 1))
```

Na podstawie wykresów diagnostycznych można stwierdzić, że liniowość jest w przybliżeniu spełniona, jednak widoczne są pojedyncze obserwacje odstające.

Testy: - Durbina-Watsona -> sprawdzenie autokorelacji reszt - Breuscha-Pagana -> sprawdzenie homoskedastyczności - Shapiro-Wilka -> sprawdzenie normalności reszt

```
dwtest(model_real_estate)
```

```
##
## Durbin-Watson test
##
## data: model_real_estate
## DW = 2.2659, p-value = 0.7611
## alternative hypothesis: true autocorrelation is greater than 0
```

```
bptest(model_real_estate)
```

```
##
## studentized Breusch-Pagan test
##
## data: model_real_estate
## BP = 15.831, df = 18, p-value = 0.6044
```

```
shapiro.test(residuals(model_real_estate))
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: residuals(model_real_estate)  
## W = 0.83399, p-value < 2.2e-16
```

Test Durбина-Watsona ($p = 0.7611$) nie daje podstaw do stwierdzenia autokorelacji reszt. Test Breusch-Pagana ($p = 0.6044$) nie wskazuje na naruszenie założenia homoskedastyczności. Test Shapiro-Wilka ($p < 2.2e-16$) wskazuje natomiast, że rozkład reszt odbiega od rozkładu normalnego.

1.2 Auto-mpg

Wczytanie i wstępne przygotowanie danych

```
auto <- read_csv("auto-mpg.csv") %>%  
  clean_names()  
  
names(auto)
```

```
## [1] "mpg"          "cylinders"    "displacement" "horsepower"   "weight"  
## [6] "acceleration" "model_year"   "origin"       "car_name"
```

Usunięcie zmiennej tekstowej, poprawienie typu danych oraz sprawdzenie braków danych.

```
auto <- auto %>%  
  mutate(horsepower = na_if(horsepower, "?"),  
         horsepower = as.numeric(horsepower))  
  
auto <- auto %>%  
  dplyr::select(-car_name)  
  
colSums(is.na(auto))
```

```
##      mpg      cylinders displacement  horsepower      weight acceleration  
##      0              0              0              6              0              0  
## model_year      origin  
##      0              0
```

```
str(auto)
```

```
## tibble [398 x 8] (S3: tbl_df/tbl/data.frame)  
## $ mpg      : num [1:398] 18 15 18 16 17 15 14 14 14 15 ...  
## $ cylinders : num [1:398] 8 8 8 8 8 8 8 8 8 8 ...  
## $ displacement: num [1:398] 307 350 318 304 302 429 454 440 455 390 ...  
## $ horsepower  : num [1:398] 130 165 150 150 140 198 220 215 225 190 ...  
## $ weight      : num [1:398] 3504 3693 3436 3433 3449 ...  
## $ acceleration: num [1:398] 12 11.5 11 12 10.5 10 9 8.5 10 8.5 ...  
## $ model_year  : num [1:398] 70 70 70 70 70 70 70 70 70 70 ...  
## $ origin      : num [1:398] 1 1 1 1 1 1 1 1 1 1 ...
```

```
summary(auto)
```

```
##      mpg      cylinders displacement horsepower      weight
## Min.   : 9.00   Min.   :3.000   Min.   : 68.0   Min.   : 46.0   Min.   :1613
## 1st Qu.:17.50   1st Qu.:4.000   1st Qu.:104.2   1st Qu.: 75.0   1st Qu.:2224
## Median :23.00   Median :4.000   Median :148.5   Median : 93.5   Median :2804
## Mean   :23.51   Mean   :5.455   Mean   :193.4   Mean   :104.5   Mean   :2970
## 3rd Qu.:29.00   3rd Qu.:8.000   3rd Qu.:262.0   3rd Qu.:126.0   3rd Qu.:3608
## Max.   :46.60   Max.   :8.000   Max.   :455.0   Max.   :230.0   Max.   :5140
##
##      acceleration      model_year      origin
## Min.   : 8.00   Min.   :70.00   Min.   :1.000
## 1st Qu.:13.82   1st Qu.:73.00   1st Qu.:1.000
## Median :15.50   Median :76.00   Median :1.000
## Mean   :15.57   Mean   :76.01   Mean   :1.573
## 3rd Qu.:17.18   3rd Qu.:79.00   3rd Qu.:2.000
## Max.   :24.80   Max.   :82.00   Max.   :3.000
##
```

Kolumna `car_name` została usunięta, ponieważ ma charakter opisowy i nie nadaje się bezpośrednio do regresji liniowej. W zmiennej `horsepower` znak `?` potraktowano jako brak danych i zamieniono na `NA`. Po tej operacji stwierdzono 6 brakujących wartości w tej zmiennej. W dalszej analizie takie obserwacje należy usunąć albo uzupełnić brakujące wartości. Zmienna `origin` opisuje pochodzenie samochodu, dlatego powinna być traktowana jako zmienna katégoryczna.

```
auto <- auto %>%
  mutate(origin = factor(origin)) %>%
  drop_na()
```


Macierz korelacji między zmiennymi objaśniającymi, wraz z wykresem rozrzutu oraz wizualizacją wartości odstających

```
cor_matrix_auto <- cor(auto %>% dplyr::select(where(is.numeric), -mpg))
knitr::kable(round(cor_matrix_auto, 2), caption = "Macierz korelacji - Auto-mpg")
```


Table 2: Macierz korelacji - Auto-mpg

	cylinders	displacement	horsepower	weight	acceleration	model_year
cylinders	1.00	0.95	0.84	0.90	-0.50	-0.35
displacement	0.95	1.00	0.90	0.93	-0.54	-0.37
horsepower	0.84	0.90	1.00	0.86	-0.69	-0.42
weight	0.90	0.93	0.86	1.00	-0.42	-0.31
acceleration	-0.50	-0.54	-0.69	-0.42	1.00	0.29
model_year	-0.35	-0.37	-0.42	-0.31	0.29	1.00

```
pairs(auto %>% dplyr::select(mpg, cylinders, displacement, horsepower, weight, acceleration, model_year))
```



```
boxplot(auto %>% dplyr::select(cylinders, displacement, horsepower, weight, acceleration, model_year))
```



Macierz korelacji pokazuje, że w zbiorze Auto-mpg występują silne zależności między częścią zmiennych objaśniających. Najwyższe korelacje występują między `cylinders` i `displacement` ($r = 0.95$), `displacement` i `weight` ($r = 0.93$) oraz `cylinders` i `weight` ($r = 0.90$). Wskazuje to na ryzyko współliniowości w modelu.

Na wykresach rozrzutu widać, że zmienna `mpg` jest silnie związana z takimi cechami jak `displacement`, `horsepower`, `weight` oraz `model_year`. Dla części zależności kierunek jest ujemny, a dla `model_year` dodatni.

Boxplot wskazuje na obecność pojedynczych wartości odstających, szczególnie dla `horsepower` i `acceleration`. Mogą one wpływać na dopasowanie modelu, dlatego należy uwzględnić je przy interpretacji wyników regresji.

Regresja wieloraka z interakcjami

```
model_auto <- lm(
  mpg ~ (cylinders + displacement + horsepower + weight + acceleration + model_year + origin)^2,
  data = auto
)

summary(model_auto)

##
## Call:
## lm(formula = mpg ~ (cylinders + displacement + horsepower + weight +
##      acceleration + model_year + origin)^2, data = auto)
##
## Residuals:
```

```

##      Min      1Q  Median      3Q      Max
## -7.6008 -1.2863  0.0813  1.2082 12.0382
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      4.401e+01  5.147e+01   0.855 0.393048
## cylinders        3.302e+00  8.187e+00   0.403 0.686976
## displacement    -3.529e-01  1.974e-01  -1.788 0.074638 .
## horsepower       5.312e-01  3.390e-01   1.567 0.117970
## weight          -3.259e-03  1.820e-02  -0.179 0.857980
## acceleration    -6.048e+00  2.147e+00  -2.818 0.005109 **
## model_year       4.833e-01  5.923e-01   0.816 0.415119
## origin2         -3.517e+01  1.260e+01  -2.790 0.005547 **
## origin3         -3.765e+01  1.426e+01  -2.640 0.008661 **
## cylinders:displacement -6.316e-03  7.106e-03  -0.889 0.374707
## cylinders:horsepower  1.452e-02  2.457e-02   0.591 0.555109
## cylinders:weight     5.703e-04  9.044e-04   0.631 0.528709
## cylinders:acceleration 3.658e-01  1.671e-01   2.189 0.029261 *
## cylinders:model_year -1.447e-01  9.652e-02  -1.499 0.134846
## cylinders:origin2    -7.210e-01  1.088e+00  -0.662 0.508100
## cylinders:origin3     1.226e+00  1.007e+00   1.217 0.224379
## displacement:horsepower -5.407e-05  2.861e-04  -0.189 0.850212
## displacement:weight   2.659e-05  1.455e-05   1.828 0.068435 .
## displacement:acceleration -2.547e-03  3.356e-03  -0.759 0.448415
## displacement:model_year 4.547e-03  2.446e-03   1.859 0.063842 .
## displacement:origin2 -3.364e-02  4.220e-02  -0.797 0.425902
## displacement:origin3  5.375e-02  4.145e-02   1.297 0.195527
## horsepower:weight    -3.407e-05  2.955e-05  -1.153 0.249743
## horsepower:acceleration -3.445e-03  3.937e-03  -0.875 0.382122
## horsepower:model_year -6.427e-03  3.891e-03  -1.652 0.099487 .
## horsepower:origin2   -4.869e-03  5.061e-02  -0.096 0.923408
## horsepower:origin3    2.289e-02  6.252e-02   0.366 0.714533
## weight:acceleration  -6.851e-05  2.385e-04  -0.287 0.774061
## weight:model_year    -8.065e-05  2.184e-04  -0.369 0.712223
## weight:origin2       2.277e-03  2.685e-03   0.848 0.397037
## weight:origin3      -4.498e-03  3.481e-03  -1.292 0.197101
## acceleration:model_year 6.141e-02  2.547e-02   2.412 0.016390 *
## acceleration:origin2  9.234e-01  2.641e-01   3.496 0.000531 ***
## acceleration:origin3  7.159e-01  3.258e-01   2.198 0.028614 *
## model_year:origin2    2.932e-01  1.444e-01   2.031 0.043005 *
## model_year:origin3    3.139e-01  1.483e-01   2.116 0.035034 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.628 on 356 degrees of freedom
## Multiple R-squared:  0.8967, Adjusted R-squared:  0.8866
## F-statistic: 88.34 on 35 and 356 DF, p-value: < 2.2e-16

```


Na podstawie wyników modelu można stwierdzić, że model regresji wielorakiej z interakcjami jest istotny statystycznie jako całość ($p < 2.2e-16$) i bardzo dobrze dopasowuje się do danych ($R^2 = 0.8967$). Oznacza to, że model wyjaśnia dużą część zmienności zmiennej mpg.

Spośród efektów głównych istotne statystycznie okazały się acceleration, origin2 oraz origin3. Istotne były również niektóre interakcje: cylinders:acceleration, acceleration:model_year,

acceleration:origin2, acceleration:origin3, model_year:origin2 oraz model_year:origin3. Pozostałe zmienne i interakcje nie wykazały istotnego wpływu na model przy poziomie istotności 0.05.

Wykresy diagnostyczne modelu

```
par(mfrow = c(2, 2))
plot(model_auto)
```



```
par(mfrow = c(1, 1))
```

Na wykresie można zauważyć pojedyncze obserwacje odstające oraz punkty o większym wpływie na model. Ostatecznie model jest dobrze dopasowany do danych pod względem współczynnika determinacji, ale nie spełnia w pełni założeń klasycznej regresji liniowej.

Testy: - Durbina-Watsona -> sprawdzenie autokorelacji reszt - Breuscha-Pagana -> sprawdzenie homoskedastyczności - Shapiro-Wilka -> sprawdzenie normalności reszt

```
vif(model_auto)
```

##		GVIF	Df	GVIF^(1/(2*Df))
##	cylinders	11036.7684	1	105.05603
##	displacement	24144.3353	1	155.38448
##	horsepower	9634.9762	1	98.15791
##	weight	13525.0893	1	116.29742
##	acceleration	1985.0502	1	44.55390

## model_year	269.4619	1	16.41530
## origin	1849328.3062	2	36.87682
## cylinders:displacement	2850.5620	1	53.39065
## cylinders:horsepower	6022.1710	1	77.60265
## cylinders:weight	4833.7588	1	69.52524
## cylinders:acceleration	757.0836	1	27.51515
## cylinders:model_year	7940.1466	1	89.10750
## cylinders:origin	23777.2626	2	12.41768
## displacement:horsepower	2177.1589	1	46.66004
## displacement:weight	3285.0378	1	57.31525
## displacement:acceleration	1055.3162	1	32.48563
## displacement:model_year	19415.2249	1	139.33853
## displacement:origin	29185.9377	2	13.07054
## horsepower:weight	2397.5110	1	48.96438
## horsepower:acceleration	136.6364	1	11.68916
## horsepower:model_year	6313.7082	1	79.45885
## horsepower:origin	29550.3006	2	13.11114
## weight:acceleration	469.6688	1	21.67184
## weight:model_year	10070.5136	1	100.35195
## weight:origin	164942.0934	2	20.15268
## acceleration:model_year	1961.3933	1	44.28762
## acceleration:origin	35304.3561	2	13.70746
## model_year:origin	888387.7843	2	30.70087

```
dwtest(model_auto)
```

```
##
## Durbin-Watson test
##
## data: model_auto
## DW = 1.7079, p-value = 0.000478
## alternative hypothesis: true autocorrelation is greater than 0
```

```
bptest(model_auto)
```

```
##
## studentized Breusch-Pagan test
##
## data: model_auto
## BP = 73.013, df = 35, p-value = 0.000173
```

```
shapiro.test(residuals(model_auto))
```

```
##
## Shapiro-Wilk normality test
##
## data: residuals(model_auto)
## W = 0.96171, p-value = 1.378e-08
```

Na podstawie wskaźników VIF można stwierdzić bardzo silną współliniowość w modelu. Oznacza to, że część zmiennych objaśniających i interakcji jest ze sobą mocno powiązana, co może utrudniać stabilną interpretację współczynników.

Test Durbina-Watsona ($p = 0.000478$) wskazuje na występowanie autokorelacji reszt. Test Breusch-Pagana ($p = 0.000173$) wskazuje na brak homoskedastyczności, czyli wariancja reszt nie jest stała. Test Shapiro-Wilka ($p = 1.378e-08$) wskazuje, że reszty nie mają rozkładu normalnego.

Model dla zbioru Auto-mpg wyjaśnia dużą część zmienności zmiennej `mpg`, jednak ze względu na silną współliniowość oraz niespełnienie części założeń regresji jego wyniki należy interpretować ostrożnie.

Zadanie 2

Regresja Poissonowska

W tej części analizowany jest model regresji Poissona dla zmiennej zależnej Y .

Funkcja wiarygodności

Ma postać:

$$L(a_0, a_1, \dots, a_p) = \prod_{i=1}^n \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!},$$

gdzie:

$$\lambda_i = \exp(a_0 + a_1 X_{i1} + \dots + a_p X_{ip}).$$

Wczytanie danych

```
poisson_data <- read.csv2("poisson.data")
```

```
names(poisson_data)
```

```
## [1] "id" "X1" "Y"
```

```
str(poisson_data)
```

```
## 'data.frame': 100 obs. of 3 variables:
## $ id: int 1 2 3 4 5 6 7 8 9 10 ...
## $ X1: num 8.75 4.78 9.53 6.29 1.91 ...
## $ Y : int 212 33 299 68 8 287 13 43 4 4 ...
```

```
summary(poisson_data)
```

```
##           id           X1           Y
## Min.      : 1.00   Min.   :0.1373   Min.    : 2.00
## 1st Qu.: 25.75   1st Qu.:3.4372   1st Qu.: 15.00
## Median : 50.50   Median :5.5927   Median : 43.50
## Mean     : 50.50   Mean    :5.4349   Mean    : 88.98
## 3rd Qu.: 75.25   3rd Qu.:7.6942   3rd Qu.:137.50
## Max.     :100.00   Max.     :9.7562   Max.     :363.00
```

Zbiór zawiera 100 obserwacji oraz 3 zmienne: `id`, `X1` i `Y`. W dalszej analizie zmienna `id` nie będzie używana w modelu, ponieważ pełni jedynie funkcję identyfikatora obserwacji. Zmienna `X1` jest zmienną objaśniającą, a `Y` zmienną zależną o wartościach całkowitych nieujemnych, więc dane nadają się do regresji Poissona.

Optymalizacja funkcji wiarygodności dla $p = 1$

Zapisano funkcję ujemnego logarytmu wiarygodności dla regresji Poissona przy $p=1$ oraz wyznaczono optymalne wartości parametrów modelu (a_0) i (a_1) za pomocą funkcji `optim()`.

```
x <- poisson_data$X1
y <- poisson_data$Y

neg_log_likelihood <- function(par, x, y) {
  a0 <- par[1]
  a1 <- par[2]

  lambda <- exp(a0 + a1 * x)

  -sum(y * log(lambda) - lambda - lfactorial(y))
}

optim_result <- optim(
  par = c(0, 0),
  fn = neg_log_likelihood,
  x = x,
  y = y,
  hessian = TRUE
)

optim_result
```

```
## $par
## [1] 1.0346121 0.4973483
##
## $value
## [1] 329.4362
##
## $counts
## function gradient
##      69      NA
##
## $convergence
## [1] 0
##
## $message
## NULL
##
## $hessian
##      [,1] [,2]
## [1,] 8898.162 71684.59
## [2,] 71684.587 603578.57
```

Optymalizacja powiodła się.

Odczytanie optymalnych parametrów.

```
a0_hat <- optim_result$par[1]
a1_hat <- optim_result$par[2]

cat("a0 =", a0_hat, "\n")
```

```
## a0 = 1.034612
```

```
cat("a1 =", a1_hat, "\n")
```

```
## a1 = 0.4973483
```

Wyznaczono oszacowania parametrów modelu: $a_0 = 1.034612$ oraz $a_1 = 0.4973483$. Oznacza to, że wraz ze wzrostem zmiennej X_1 rośnie oczekiwana wartość parametru λ , a więc także oczekiwana wartość zmiennej Y .

Model regresji Poissona przy użyciu funkcji glm()

```
model_poisson <- glm(Y ~ X1, data = poisson_data, family = poisson)
```

```
model_poisson
```

```
##
## Call:  glm(formula = Y ~ X1, family = poisson, data = poisson_data)
##
## Coefficients:
## (Intercept)          X1
##      1.0330      0.4975
##
## Degrees of Freedom: 99 Total (i.e. Null);  98 Residual
## Null Deviance:      9945
## Residual Deviance: 101.9    AIC: 662.9
```

```
summary(model_poisson)
```

```
##
## Call:
## glm(formula = Y ~ X1, family = poisson, data = poisson_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) 1.032997   0.051017  20.25  <2e-16 ***
## X1          0.497547   0.006194  80.33  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 9945.17  on 99  degrees of freedom
## Residual deviance: 101.89  on 98  degrees of freedom
## AIC: 662.87
##
## Number of Fisher Scoring iterations: 4
```

Dopasowanie funkcją `glm()` dało bardzo zbliżone oszacowania parametrów do tych uzyskanych wcześniej funkcją `optim()` (wartości (*Intercept*) = 1.0330 oraz *X1* = 0.4975). Oba współczynniki są istotne statystycznie ($p < 2e-16$), co oznacza, że zmienna *X1* ma istotny wpływ na zmienną *Y*.

Interpretacja wyników modelu

a) **Deviance Residuals** to reszty, które pokazują, jak bardzo obserwacje różnią się od wartości przewidywanych przez model. Powinny być możliwie małe i w przybliżeniu symetrycznie rozmieszczone wokół zera.

b) W modelu istotne statystycznie są współczynniki (*Intercept*) oraz *X1*, ponieważ dla obu wartości p są mniejsze od 0.05. Oszacowania parametrów są praktycznie takie same jak te uzyskane funkcją `optim()`, co potwierdza poprawność wcześniejszej optymalizacji.

c) **Null deviance** opisuje niedopasowanie modelu zerowego, czyli takiego, który nie zawiera żadnych zmiennych objaśniających. **Residual deviance** opisuje niedopasowanie modelu po uwzględnieniu zmiennej *X1*. Duży spadek z **Null deviance** do **Residual deviance** oznacza, że model z *X1* znacznie lepiej opisuje dane niż model zerowy.

Zadanie 3

Regresja Poissonowska dla danych ships

Celem zadania jest dopasowanie modelu regresji Poissona dla zmiennej **incidents**, sprawdzenie, które atrybuty należy uwzględnić w modelu, oraz ocena reszt dewiacyjnych.

```
data("ships", package = "MASS")
```

```
str(ships)
```

```
## 'data.frame': 40 obs. of 5 variables:
## $ type      : Factor w/ 5 levels "A","B","C","D",...: 1 1 1 1 1 1 1 1 2 2 ...
## $ year      : int 60 60 65 65 70 70 75 75 60 60 ...
## $ period    : int 60 75 60 75 60 75 60 75 60 75 ...
## $ service   : int 127 63 1095 1095 1512 3353 0 2244 44882 17176 ...
## $ incidents : int 0 0 3 4 6 18 0 11 39 29 ...
```

```
summary(ships)
```

	type	year	period	service	incidents
##	A:8	Min. :60.00	Min. :60.0	Min. : 0.0	Min. : 0.0
##	B:8	1st Qu.:63.75	1st Qu.:60.0	1st Qu.: 175.8	1st Qu.: 0.0
##	C:8	Median :67.50	Median :67.5	Median : 782.0	Median : 2.0
##	D:8	Mean :67.50	Mean :67.5	Mean : 4089.3	Mean : 8.9
##	E:8	3rd Qu.:71.25	3rd Qu.:75.0	3rd Qu.: 2078.5	3rd Qu.:11.0
##		Max. :75.00	Max. :75.0	Max. :44882.0	Max. :58.0

```
ships
```

```
## type year period service incidents
## 1 A 60 60 127 0
```

## 2	A	60	75	63	0
## 3	A	65	60	1095	3
## 4	A	65	75	1095	4
## 5	A	70	60	1512	6
## 6	A	70	75	3353	18
## 7	A	75	60	0	0
## 8	A	75	75	2244	11
## 9	B	60	60	44882	39
## 10	B	60	75	17176	29
## 11	B	65	60	28609	58
## 12	B	65	75	20370	53
## 13	B	70	60	7064	12
## 14	B	70	75	13099	44
## 15	B	75	60	0	0
## 16	B	75	75	7117	18
## 17	C	60	60	1179	1
## 18	C	60	75	552	1
## 19	C	65	60	781	0
## 20	C	65	75	676	1
## 21	C	70	60	783	6
## 22	C	70	75	1948	2
## 23	C	75	60	0	0
## 24	C	75	75	274	1
## 25	D	60	60	251	0
## 26	D	60	75	105	0
## 27	D	65	60	288	0
## 28	D	65	75	192	0
## 29	D	70	60	349	2
## 30	D	70	75	1208	11
## 31	D	75	60	0	0
## 32	D	75	75	2051	4
## 33	E	60	60	45	0
## 34	E	60	75	0	0
## 35	E	65	60	789	7
## 36	E	65	75	437	7
## 37	E	70	60	1157	5
## 38	E	70	75	2161	12
## 39	E	75	60	0	0
## 40	E	75	75	542	1

Zbiór `ships` zawiera 40 obserwacji i 5 zmiennych: `type`, `year`, `period`, `service` oraz `incidents`. Zmienna `type` jest już zmienną kategoriową, natomiast `year` i `period` są zapisane jako liczby, ale w tym zadaniu powinny być traktowane jako zmienne kategoriowe opisujące grupy statków i okresy. Zmienna `incidents` jest zmienną zależną, a `service` opisuje czas eksploatacji statków.

```
ships$year <- factor(ships$year)
ships$period <- factor(ships$period)

#usunięcie service = 0, bo log z zera nie jest określony
ships2 <- ships %>%
  filter(service > 0)

model_ships <- glm(incidents ~ type + year + period + offset(log(service)), data = ships2, family = poisson)
```

```
summary(model_ships)
```

```
##
## Call:
## glm(formula = incidents ~ type + year + period + offset(log(service)),
##      family = poisson, data = ships2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -6.40590    0.21744 -29.460 < 2e-16 ***
## typeB       -0.54334    0.17759  -3.060 0.00222 **
## typeC       -0.68740    0.32904  -2.089 0.03670 *
## typeD       -0.07596    0.29058  -0.261 0.79377
## typeE        0.32558    0.23588   1.380 0.16750
## year65       0.69714    0.14964   4.659 3.18e-06 ***
## year70       0.81843    0.16977   4.821 1.43e-06 ***
## year75       0.45343    0.23317   1.945 0.05182 .
## period75     0.38447    0.11827   3.251 0.00115 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 146.328  on 33  degrees of freedom
## Residual deviance:  38.695  on 25  degrees of freedom
## AIC: 154.56
##
## Number of Fisher Scoring iterations: 5
```

```
drop1(model_ships, test = "Chisq")
```


```
## Single term deletions
##
## Model:
## incidents ~ type + year + period + offset(log(service))
##      Df Deviance    AIC    LRT  Pr(>Chi)
## <none>      38.695 154.56
## type    4   62.365 170.23 23.670 9.300e-05 ***
## year    3   70.103 179.97 31.408 6.975e-07 ***
## period  1   49.355 163.22 10.660 0.001095 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

W modelu uwzględniono zmienne `type`, `year` i `period`, natomiast `service` wprowadzono jako składnik `offset(log(service))`, aby uwzględnić różny czas eksploatacji statków.


Program potraktował `type`, `year` i `period` jako zmienne katégoriczne i zakodował je za pomocą zmiennych zero-jedynkowych względem kategorii bazowych. Pojedyncze współczynniki, takie jak `typeB` czy `year65`, opisują więc różnice względem poziomu referencyjnego.

Na podstawie testu `drop1(model_ships, test = "Chisq")` stwierdzono, że atrybuty `type`, `year` i `period` są istotne statystycznie, ponieważ usunięcie każdego z nich powoduje istotne pogorszenie dopasowania modelu ($p < 0.05$). Oznacza to, że wszystkie te zmienne należy pozostawić w modelu.

```
reszty_ships <- resid(model_ships, type = "deviance")  
  
plot(reszty_ships, ylab = "Reszty dewiancyjne", main = "Reszty dewiancyjne - ships")  
abline(h = 0, lty = 2)
```



```
qqnorm(reszty_ships)  
qqline(reszty_ships)
```

```
shapiro.test(reszty_ships)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  reszty_ships
## W = 0.94061, p-value = 0.06427
```

Na podstawie wykresu reszt dewiancyjnych nie widać bardzo silnego, wyraźnego wzorca, chociaż pojawiają się pojedyncze większe odchylenia. Na wykresie Q-Q większość punktów leży blisko prostej, więc rozkład reszt jest w przybliżeniu zbliżony do normalnego. Potwierdza to także test Shapiro-Wilka, dla którego otrzymano $p = 0.06427$, czyli wartość większą od 0.05. Oznacza to, że nie ma podstaw do odrzucenia założenia o normalności reszt.

Zadanie 4

Regresja Poissonowska dla danych `esoph`

W tej części analizowany jest zbiór `esoph`. Celem jest dopasowanie modelu regresji Poissona dla zmiennej `ncases`, wskazanie istotnych atrybutów, zbudowanie prostszego modelu oraz ocena dopasowania modelu na podstawie reszt.

```
data("esoph")
```

```
str(esoph)
```

```
## 'data.frame': 88 obs. of 5 variables:
## $ agegp : Ord.factor w/ 6 levels "25-34"<"35-44"<...: 1 1 1 1 1 1 1 1 1 1 ...
## $ alcgp : Ord.factor w/ 4 levels "0-39g/day"<"40-79"<...: 1 1 1 1 2 2 2 2 3 3 ...
## $ tobgp : Ord.factor w/ 4 levels "0-9g/day"<"10-19"<...: 1 2 3 4 1 2 3 4 1 2 ...
## $ ncases : num 0 0 0 0 0 0 0 0 0 0 ...
## $ ncontrols: num 40 10 6 5 27 7 4 7 2 1 ...
```

```
summary(esoph)
```

##	agegp	alcgp	tobgp	ncases	ncontrols
##	25-34:15	0-39g/day:23	0-9g/day:24	Min. : 0.000	Min. : 0.000
##	35-44:15	40-79 :23	10-19 :24	1st Qu.: 0.000	1st Qu.: 1.000
##	45-54:16	80-119 :21	20-29 :20	Median : 1.000	Median : 4.000
##	55-64:16	120+ :21	30+ :20	Mean : 2.273	Mean : 8.807
##	65-74:15			3rd Qu.: 4.000	3rd Qu.:10.000
##	75+ :11			Max. :17.000	Max. :60.000

```
esoph
```

##	agegp	alcgp	tobgp	ncases	ncontrols
## 1	25-34	0-39g/day	0-9g/day	0	40
## 2	25-34	0-39g/day	10-19	0	10
## 3	25-34	0-39g/day	20-29	0	6
## 4	25-34	0-39g/day	30+	0	5
## 5	25-34	40-79	0-9g/day	0	27
## 6	25-34	40-79	10-19	0	7
## 7	25-34	40-79	20-29	0	4
## 8	25-34	40-79	30+	0	7
## 9	25-34	80-119	0-9g/day	0	2
## 10	25-34	80-119	10-19	0	1
## 11	25-34	80-119	30+	0	2
## 12	25-34	120+	0-9g/day	0	1
## 13	25-34	120+	10-19	1	0
## 14	25-34	120+	20-29	0	1
## 15	25-34	120+	30+	0	2
## 16	35-44	0-39g/day	0-9g/day	0	60
## 17	35-44	0-39g/day	10-19	1	13
## 18	35-44	0-39g/day	20-29	0	7
## 19	35-44	0-39g/day	30+	0	8
## 20	35-44	40-79	0-9g/day	0	35
## 21	35-44	40-79	10-19	3	20
## 22	35-44	40-79	20-29	1	13
## 23	35-44	40-79	30+	0	8
## 24	35-44	80-119	0-9g/day	0	11
## 25	35-44	80-119	10-19	0	6
## 26	35-44	80-119	20-29	0	2
## 27	35-44	80-119	30+	0	1
## 28	35-44	120+	0-9g/day	2	1

## 29	35-44	120+	10-19	0	3
## 30	35-44	120+	20-29	2	2
## 31	45-54	0-39g/day	0-9g/day	1	45
## 32	45-54	0-39g/day	10-19	0	18
## 33	45-54	0-39g/day	20-29	0	10
## 34	45-54	0-39g/day	30+	0	4
## 35	45-54	40-79	0-9g/day	6	32
## 36	45-54	40-79	10-19	4	17
## 37	45-54	40-79	20-29	5	10
## 38	45-54	40-79	30+	5	2
## 39	45-54	80-119	0-9g/day	3	13
## 40	45-54	80-119	10-19	6	8
## 41	45-54	80-119	20-29	1	4
## 42	45-54	80-119	30+	2	2
## 43	45-54	120+	0-9g/day	4	0
## 44	45-54	120+	10-19	3	1
## 45	45-54	120+	20-29	2	1
## 46	45-54	120+	30+	4	0
## 47	55-64	0-39g/day	0-9g/day	2	47
## 48	55-64	0-39g/day	10-19	3	19
## 49	55-64	0-39g/day	20-29	3	9
## 50	55-64	0-39g/day	30+	4	2
## 51	55-64	40-79	0-9g/day	9	31
## 52	55-64	40-79	10-19	6	15
## 53	55-64	40-79	20-29	4	13
## 54	55-64	40-79	30+	3	3
## 55	55-64	80-119	0-9g/day	9	9
## 56	55-64	80-119	10-19	8	7
## 57	55-64	80-119	20-29	3	3
## 58	55-64	80-119	30+	4	0
## 59	55-64	120+	0-9g/day	5	5
## 60	55-64	120+	10-19	6	1
## 61	55-64	120+	20-29	2	1
## 62	55-64	120+	30+	5	1
## 63	65-74	0-39g/day	0-9g/day	5	43
## 64	65-74	0-39g/day	10-19	4	10
## 65	65-74	0-39g/day	20-29	2	5
## 66	65-74	0-39g/day	30+	0	2
## 67	65-74	40-79	0-9g/day	17	17
## 68	65-74	40-79	10-19	3	7
## 69	65-74	40-79	20-29	5	4
## 70	65-74	80-119	0-9g/day	6	7
## 71	65-74	80-119	10-19	4	8
## 72	65-74	80-119	20-29	2	1
## 73	65-74	80-119	30+	1	0
## 74	65-74	120+	0-9g/day	3	1
## 75	65-74	120+	10-19	1	1
## 76	65-74	120+	20-29	1	0
## 77	65-74	120+	30+	1	0
## 78	75+	0-39g/day	0-9g/day	1	17
## 79	75+	0-39g/day	10-19	2	4
## 80	75+	0-39g/day	30+	1	2
## 81	75+	40-79	0-9g/day	2	3
## 82	75+	40-79	10-19	1	2

## 83	75+	40-79	20-29	0	3
## 84	75+	40-79	30+	1	0
## 85	75+	80-119	0-9g/day	1	0
## 86	75+	80-119	10-19	1	0
## 87	75+	120+	0-9g/day	2	0
## 88	75+	120+	10-19	1	0

Zbiór `esoph` zawiera 88 obserwacji i 5 zmiennych. Zmienne `agegp`, `alcgp` oraz `tobgp` są zmiennymi porządkowymi i mogą zostać użyte jako atrybuty objaśniające. Zmienna `ncases` będzie zmienną zależną, natomiast `ncontrols` opisuje liczebność grup i zostanie uwzględniona w modelu jako składnik `offset`.

Dopasowano model regresji Poissona, w którym zmienną zależną jest `ncases`, a zmienne `agegp`, `alcgp` i `tobgp` pełnią rolę atrybutów objaśniających. Zmienna `ncontrols` została uwzględniona jako `offset`, ponieważ opisuje liczebność grup.

```
#usuniecie ncontrols = 0, bo log z zera nie jest określony
esoph2 <- esoph %>%
  filter(ncontrols > 0)

model_esoph <- glm(
  ncases ~ agegp + alcgp + tobgp + offset(log(ncontrols)),
  data = esoph2,
  family = poisson
)

summary(model_esoph)
```

```
##
## Call:
## glm(formula = ncases ~ agegp + alcgp + tobgp + offset(log(ncontrols)),
##      family = poisson, data = esoph2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -3.9107    206.2276  -0.019   0.9849
## agegp.L       12.5592    739.4675   0.017   0.9864
## agegp.Q      -10.0607    675.0384  -0.015   0.9881
## agegp.C        5.6734    461.1390   0.012   0.9902
## agegp^4       -2.8307    233.8402  -0.012   0.9903
## agegp^5        0.7160     77.9469   0.009   0.9927
## alcgp.L        2.0460     0.1844  11.095 < 2e-16 ***
## alcgp.Q       -0.1111     0.1648  -0.674   0.5002
## alcgp.C        0.3626     0.1440   2.517   0.0118 *
## tobgp.L        0.9439     0.1826   5.169 2.36e-07 ***
## tobgp.Q        0.2494     0.1717   1.453   0.1463
## tobgp.C        0.2207     0.1612   1.369   0.1710
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 390.970  on 75  degrees of freedom
## Residual deviance:  89.255  on 64  degrees of freedom
## AIC: 254.54
```

```
##
## Number of Fisher Scoring iterations: 16

drop1(model_esoph, test = "Chisq")

## Single term deletions
##
## Model:
## ncases ~ agegp + alcgp + tobgp + offset(log(ncontrols))
##      Df Deviance   AIC    LRT Pr(>Chi)
## <none>      89.255 254.54
## agegp   5  244.104 399.39 154.848 < 2.2e-16 ***
## alcgp   3  215.721 375.01 126.466 < 2.2e-16 ***
## tobgp   3  113.399 272.69  24.144 2.331e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Na podstawie testu `drop1(model_esoph, test = "Chisq")` stwierdzono, że atrybuty `agegp`, `alcgp` i `tobgp` są istotne statystycznie, ponieważ usunięcie każdego z nich prowadzi do istotnego wzrostu dewiacji i pogorszenia dopasowania modelu ($p < 0.05$). Największy wpływ na model ma `agegp`, następnie `alcgp`, a najmniejszy `tobgp`. Wszystkie te zmienne należy więc pozostawić w modelu.

Dla porównania dopasowano także model uproszczony bez zmiennej `agegp`.

```
model_esoph_reduced <- glm(
  ncases ~ alcgp + tobgp + offset(log(ncontrols)),
  data = esoph2,
  family = poisson
)

summary(model_esoph_reduced)

##
## Call:
## glm(formula = ncases ~ alcgp + tobgp + offset(log(ncontrols)),
##      family = poisson, data = esoph2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.94869    0.08888 -10.674  <2e-16 ***
## alcgp.L      2.01895    0.18116  11.144  <2e-16 ***
## alcgp.Q     -0.12150    0.16114  -0.754   0.4509
## alcgp.C      0.19572    0.14135   1.385   0.1662
## tobgp.L      0.42233    0.17925   2.356   0.0185 *
## tobgp.Q     -0.09097    0.16900  -0.538   0.5904
## tobgp.C      0.13291    0.16016   0.830   0.4066
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 390.97  on 75  degrees of freedom
## Residual deviance: 244.10  on 69  degrees of freedom
```


```
## AIC: 399.39
##
## Number of Fisher Scoring iterations: 6
```

Model uproszczony z atrybutami `alcgp` i `tobgp` jest wyraźnie gorzej dopasowany od modelu pełnego. Świadczy o tym wzrost `Residual deviance` z 89.255 do 244.10 oraz wzrost AIC z 254.54 do 399.39. Oznacza to, że usunięcie `agegp` pogarsza jakość modelu, więc zmienna ta powinna pozostać w modelu pełnym.


Warunki resyduów

```
reszty_esoph <- resid(model_esoph, type = "deviance")

plot(reszty_esoph, ylab = "Reszty dewiancyjne", main = "Reszty dewiancyjne - esoph")
abline(h = 0, lty = 2)
```



```
qqnorm(reszty_esoph)
qqline(reszty_esoph)
```



```
shapiro.test(reszty_esoph)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  reszty_esoph
## W = 0.96912, p-value = 0.06061
```

Na podstawie wykresu reszt dewiancyjnych nie widać bardzo silnego wzorca, choć część obserwacji ma reszty równe lub bliskie zero. Wykres Q-Q pokazuje, że większość punktów leży blisko prostej, więc rozkład reszt jest w przybliżeniu zbliżony do normalnego. Potwierdza to również test Shapiro-Wilka, dla którego otrzymano $p = 0.06061$, czyli wartość większą od 0.05. Oznacza to, że nie ma podstaw do odrzucenia założenia o normalności reszt.

Zadanie 5

Regresja porządkowa CLM

W tej części analizowany jest zbiór `clm.data`. Celem jest dopasowanie modelu regresji porządkowej CLM dla zmiennej `satysfakcja` oraz sprawdzenie, które atrybuty mają istotny wpływ na model.

```
clm_data <- read.csv("clm.data")
str(clm_data)
```

```
## 'data.frame': 100 obs. of 4 variables:
## $ id : int 1 2 3 4 5 6 7 8 9 10 ...
## $ satysfakcja: int 3 3 2 2 3 5 4 1 2 3 ...
## $ cena : num 96.9 156.2 89.8 139.2 122.2 ...
## $ obsluga : int 10 7 9 7 10 4 8 9 9 9 ...
```

```
summary(clm_data)
```

```
##      id      satysfakcja      cena      obsluga
## Min.   : 1.00   Min.   :1.00   Min.   : 50.95   Min.   : 1.00
## 1st Qu.: 25.75   1st Qu.:2.00   1st Qu.: 92.07   1st Qu.: 3.00
## Median : 50.50   Median :3.00   Median :127.36   Median : 5.00
## Mean   : 50.50   Mean   :2.93   Mean   :127.81   Mean   : 5.53
## 3rd Qu.: 75.25   3rd Qu.:4.00   3rd Qu.:159.07   3rd Qu.: 9.00
## Max.   :100.00   Max.   :5.00   Max.   :197.85   Max.   :10.00
```

```
head(clm_data)
```

```
##   id satysfakcja      cena obsluga
## 1  1           3 96.86722      10
## 2  2           3 156.24355       7
## 3  3           2  89.75267       9
## 4  4           2 139.15148       7
## 5  5           3 122.19347      10
## 6  6           5  89.75491       4
```

Zbiór `clm.data` zawiera 100 obserwacji i 4 zmienne: `id`, `satysfakcja`, `cena` oraz `obsługa`. Kolumna `id` pełni jedynie funkcję identyfikatora, więc nie będzie używana w modelu. Zmienna `satysfakcja` jest zmienną zależną i powinna zostać potraktowana jako zmienna porządkowa. Do modelu wybrano atrybuty `cena` i `obsługa`.

```
clm_data <- dplyr::select(clm_data, -id)

clm_data$satysfakcja <- ordered(clm_data$satysfakcja)

str(clm_data)
```

```
## 'data.frame': 100 obs. of 3 variables:
## $ satysfakcja: Ord.factor w/ 5 levels "1"<"2"<"3"<"4"<...: 3 3 2 2 3 5 4 1 2 3 ...
## $ cena : num 96.9 156.2 89.8 139.2 122.2 ...
## $ obsluga : int 10 7 9 7 10 4 8 9 9 9 ...
```

```
model_clm <- clm(satysfakcja ~ cena + obsluga, data = clm_data)
```

```
summary(model_clm)
```

```
## formula: satysfakcja ~ cena + obsluga
## data:   clm_data
##
## link threshold nobs logLik AIC      niter max.grad cond.H
## logit flexible 100 -159.66 331.31 4(0) 1.69e-12 1.2e+06
```



```
##
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## cena      -0.005178   0.004391  -1.179   0.238
## obsługa   0.014197   0.058268   0.244   0.808
##
## Threshold coefficients:
##           Estimate Std. Error z value
## 1|2 -1.926818    0.748672  -2.574
## 2|3 -0.953354    0.730469  -1.305
## 3|4 -0.001363    0.719511  -0.002
## 4|5  0.879775    0.725654   1.212
```

Po dopasowaniu modelu CLM okazało się, że ani **cena**, ani **obsługa** nie są istotne statystycznie, ponieważ dla obu zmiennych wartości p są większe od 0.05.

Kolumna **Estimate** zawiera oszacowania współczynników modelu. Znak współczynnika wskazuje kierunek wpływu zmiennej na przechodzenie do wyższych kategorii zmiennej **satysfakcja**. Współczynnik przy **cena** jest ujemny, a przy **obsługa** dodatni, ale ponieważ oba efekty są nieistotne statystycznie, nie można ich traktować jako potwierdzonych zależności.

Std. Error oznacza błąd standardowy oszacowania współczynnika. **z value** jest ilorazem **Estimate** i **Std. Error**, a **Pr(>|z|)** to wartość p , na podstawie której ocenia się istotność współczynnika.

Wartości 1|2, 2|3, 3|4 i 4|5 są progami oddzielającymi kolejne poziomy zmiennej **satysfakcja**. **logLik** oznacza wartość logarytmu funkcji wiarygodności, natomiast **AIC** służy do porównywania modeli — mniejsza wartość oznacza lepszy model spośród porównywanych.

Zadanie 6

Regresja porządkowa dla danych wine

W tej części wykorzystano zbiór **wine** z pakietu **ordinal**. Najpierw dopasowano model regresji porządkowej dla zmiennej **rating**, następnie wykonano predykcje na danych uczących, a na końcu porównano regresję porządkową z regresją logistyczną po zakodowaniu zmiennej zależnej do postaci 0/1.

```
data("wine", package = "ordinal")
```

```
str(wine)
```

```
## 'data.frame':   72 obs. of  6 variables:
## $ response: num  36 48 47 67 77 60 83 90 17 22 ...
## $ rating : Ord.factor w/ 5 levels "1"<"2"<"3"<"4"<...: 2 3 3 4 4 4 5 5 1 2 ...
## $ temp : Factor w/ 2 levels "cold","warm": 1 1 1 1 2 2 2 2 1 1 ...
## $ contact : Factor w/ 2 levels "no","yes": 1 1 2 2 1 1 2 2 1 1 ...
## $ bottle : Factor w/ 8 levels "1","2","3","4",...: 1 2 3 4 5 6 7 8 1 2 ...
## $ judge : Factor w/ 9 levels "1","2","3","4",...: 1 1 1 1 1 1 1 1 2 2 ...
```

```
summary(wine)
```

```
##      response      rating      temp      contact      bottle      judge
## Min.      :12.00      1: 5      cold:36      no :36      1      : 9      1      : 8
```

```
## 1st Qu.:32.00 2:22 warm:36 yes:36 2 : 9 2 : 8
## Median :46.00 3:26 3 : 9 3 : 8
## Mean :47.22 4:12 4 : 9 4 : 8
## 3rd Qu.:60.00 5: 7 5 : 9 5 : 8
## Max. :90.00 6 : 9 6 : 8
## (Other):18 (Other):24
```

```
model_wine <- clm(rating ~ contact + temp, data = wine)
```

```
summary(model_wine)
```

```
## formula: rating ~ contact + temp
## data: wine
##
## link threshold nobs logLik AIC niter max.grad cond.H
## logit flexible 72 -86.49 184.98 6(0) 4.01e-12 2.7e+01
##
## Coefficients:
## Estimate Std. Error z value Pr(>|z|)
## contactyes 1.5278 0.4766 3.205 0.00135 **
## tempwarm 2.5031 0.5287 4.735 2.19e-06 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Threshold coefficients:
## Estimate Std. Error z value
## 1|2 -1.3444 0.5171 -2.600
## 2|3 1.2508 0.4379 2.857
## 3|4 3.4669 0.5978 5.800
## 4|5 5.0064 0.7309 6.850
```

```
pred_wine <- predict(
  model_wine,
  newdata = wine[, c("contact", "temp")],
  type = "prob"
)
```

```
head(pred_wine$fit)
```

```
##          1          2          3          4          5
## 1 0.20679013 0.5706497 0.1922909 0.02361882 0.00665041
## 2 0.20679013 0.5706497 0.1922909 0.02361882 0.00665041
## 3 0.05354601 0.3776461 0.4430599 0.09582084 0.02992711
## 4 0.05354601 0.3776461 0.4430599 0.09582084 0.02992711
## 5 0.02088771 0.2014157 0.5015755 0.20049402 0.07562701
## 6 0.02088771 0.2014157 0.5015755 0.20049402 0.07562701
```

W modelu dla zmiennej **rating** obie zmienne objaśniające okazały się istotne statystycznie: **contactyes** oraz **tempwarm**, ponieważ dla obu wartości *p* są mniejsze od 0.05. Oznacza to, że sposób kontaktu oraz temperatura mają istotny wpływ na ocenę wina.

Wyniki predykcji są pokazane jako tabela prawdopodobieństw. Każdy wiersz odpowiada jednej obserwacji, a każda kolumna jednej kategorii zmiennej **rating**. Wartości w wierszu sumują się do 1 i pokazują prawdopodobieństwo przypisania obserwacji do kolejnych ocen.

Zakodowanie zmiennej do 0/1

```
wine2 <- wine

wine2$rating_bin <- ifelse(as.numeric(wine2$rating) < 4, 0, 1)

table(wine2$rating_bin)

##
##  0  1
## 53 19
```

Zmienna `rating` została przekształcona do postaci binarnej. Wartości mniejsze niż 4 oznaczono jako 0, a wartości większe lub równe 4 jako 1.

Regresja porządkowa i logistyczna

```
wine2$rating_bin_clm <- ordered(wine2$rating_bin, levels = c(0, 1))

model_wine_clm_bin <- clm(rating_bin_clm ~ contact + temp, data = wine2)
summary(model_wine_clm_bin)

## formula: rating_bin_clm ~ contact + temp
## data:      wine2
##
##  link  threshold nobs logLik AIC   niter max.grad cond.H
##  logit flexible  72   -28.73 63.46 6(0)  3.21e-12 3.1e+01
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## contactyes    1.8102     0.6927   2.613 0.008964 **
## tempwarm      3.0312     0.8525   3.556 0.000377 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Threshold coefficients:
##              Estimate Std. Error z value
## 0|1    4.0719     0.9393   4.335

model_wine_logit <- glm(rating_bin ~ contact + temp, data = wine2, family = binomial)
summary(model_wine_logit)

##
## Call:
## glm(formula = rating_bin ~ contact + temp, family = binomial,
##      data = wine2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
```

```

## (Intercept)  -4.0719      0.9392  -4.335 1.45e-05 ***
## contactyes   1.8102      0.6927   2.613 0.008963 **
## tempwarm     3.0312      0.8525   3.556 0.000377 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 83.100  on 71  degrees of freedom
## Residual deviance: 57.457  on 69  degrees of freedom
## AIC: 63.457
##
## Number of Fisher Scoring iterations: 5

```

Po zakodowaniu zmiennej `rating` do postaci 0/1 dopasowano dwa modele: regresję porządkową CLM oraz regresję logistyczną. Wyniki obu modeli są bardzo podobne. W obu przypadkach istotne statystycznie okazały się zmienne `contact` oraz `temp`, a kierunek ich wpływu jest taki sam.

W modelu logistycznym współczynniki przy `contactyes` i `tempwarm` są dodatnie, co oznacza, że zwiększają prawdopodobieństwo uzyskania wartości 1, czyli oceny większej lub równej 4. W modelu CLM otrzymano zgodne wyniki, a przy dwóch klasach model porządkowy i logistyczny dają praktycznie równoważne wnioski.

Można więc stwierdzić, że po sprowadzeniu zmiennej zależnej do dwóch klas wyniki regresji porządkowej i logistycznej nie różnią się istotnie interpretacyjnie.