

Predykcja progresji cukrzycy przy użyciu metod drzewiastych

Katarzyna Wesołowska

2026-06-09

Contents

1	Cel badania	1
2	Opis danych	2
3	Przygotowanie danych	2
4	Utworzenie zmiennej celu	3
5	Eksploracyjna analiza danych	3
6	Metodologia badania	6
7	Opis zastosowanych metod	6
7.1	CART	6
7.2	Random Forest	6
7.3	XGBoost	6
8	Wyniki eksperymentów	7
9	Analiza predykcji i błędów	8
10	Ważność zmiennych	9
11	Wnioski	10

1 Cel badania

Celem projektu była ocena, czy bardziej zaawansowane modele drzewiaste poprawiają przewidywanie zmian stanu zdrowia pacjentów z cukrzycą. W analizie porównano trzy podejścia: pojedyncze drzewo decyzyjne CART, Random Forest oraz XGBoost.

Problem predykcyjny został potraktowany jako zadanie regresji. Zmienną celu była średnia glikemia pacjenta w kolejnym dostępnym dniu pomiarowym. Takie podejście pozwala sprawdzić, czy na podstawie wcześniejszych pomiarów glukozy, informacji o insulinie, posiłkach i aktywności fizycznej można przewidywać przyszły poziom glikemii.

2 Opis danych

W projekcie wykorzystano zbiór **Diabetes Dataset** z repozytorium UCI Machine Learning Repository. Dane mają postać dzienników pacjentów. Każdy rekord zawiera datę, godzinę, kod zdarzenia oraz wartość. Zdarzenia obejmują między innymi pomiary glukozy, dawki insuliny, posiłki, aktywność fizyczną oraz objawy hipoglikemii.

Źródło danych: <https://archive.ics.uci.edu/dataset/34/diabetes>

Po wczytaniu danych otrzymano 29290 rekordów surowych pochodzących od 70 pacjentów. Dane wymagały przekształcenia, ponieważ pojedyncze rekordy oznaczały zdarzenia medyczne, a nie gotowe obserwacje do modelowania.

Table 1: Słownik wybranych kodów zdarzeń w zbiorze danych.

code	description
33	Regular insulin dose
34	NPH insulin dose
35	UltraLente insulin dose
48	Unspecified blood glucose measurement
57	Unspecified blood glucose measurement
58	Pre-breakfast blood glucose measurement
59	Post-breakfast blood glucose measurement
60	Pre-lunch blood glucose measurement
61	Post-lunch blood glucose measurement
62	Pre-supper blood glucose measurement
63	Post-supper blood glucose measurement
64	Pre-snack blood glucose measurement
65	Hypoglycemic symptoms
66	Typical meal ingestion
67	More-than-usual meal ingestion
68	Less-than-usual meal ingestion
69	Typical exercise activity
70	More-than-usual exercise activity
71	Less-than-usual exercise activity
72	Unspecified special event

3 Przygotowanie danych

Na podstawie kodów zdarzeń wydzielono kilka grup informacji: pomiary glukozy, dawki insuliny, posiłki, aktywność fizyczną oraz objawy hipoglikemii. Następnie dane zagregowano do poziomu **pacjent-dzień**. Dzięki temu jedna obserwacja odpowiadała jednemu pacjentowi w jednym dniu.

Dla każdego pacjenta i dnia obliczono między innymi średnią, minimalną i maksymalną glikemię, odchylenie standardowe glikemii, liczbę pomiarów, sumę dawek insuliny oraz liczbę zdarzeń związanych z posiłkami, aktywnością i hipoglikemią.

Table 2: Dziesięć najczęściej występujących typów zdarzeń.

code	n	description
33	9482	Regular insulin dose
34	3829	NPH insulin dose

code	n	description
58	3517	Pre-breakfast blood glucose measurement
62	3159	Pre-supper blood glucose measurement
60	2770	Pre-lunch blood glucose measurement
48	1883	Unspecified blood glucose measurement
35	1053	UltraLente insulin dose
57	990	Unspecified blood glucose measurement
64	904	Pre-snack blood glucose measurement
65	331	Hypoglycemic symptoms

Po agregacji do poziomu dziennego uzyskano 3859 obserwacji. Średnia dzienna glikemia w całym zbiorze wyniosła 161.64, mediana 154.8, a zakres wartości wyniósł od 23 do 422.

4 Utworzenie zmiennej celu

W celu przewidywania przyszłego stanu pacjenta utworzono zmienną celu `target_next_glucose`, oznaczającą średnią glikemię pacjenta w następnym dostępnym dniu pomiarowym. Dodatkowo obliczono zmienną `target_change`, czyli różnicę pomiędzy glikemią w następnym dniu a glikemią w dniu bieżącym.

Do modelu dodano również zmienne opóźnione, takie jak glikemia z poprzedniego dnia, glikemia sprzed dwóch dni oraz średnia krocząca z trzech ostatnich wartości.

Table 3: Podstawowe informacje o zbiorze po przygotowaniu danych.

liczba_obserwacji	liczba_pacjentow	średnia_glikemia	średnia_glikemia_następny_dzień	średnia_zmiana
3789	70	161.507	161.598	0.091

Po utworzeniu zmiennej celu w analizie pozostało 3789 obserwacji. Średnia zmiana glikemii między kolejnymi dostępnymi dniami była bliska zeru, co oznacza, że w całym zbiorze nie występował wyraźny globalny trend wzrostowy ani spadkowy. Jednocześnie przebiegi pojedynczych pacjentów wskazują na dużą zmienność indywidualną.

5 Eksploracyjna analiza danych

Rozkład średniej dziennej glikemii jest prawostronnie skośny. Większość obserwacji znajduje się w środkowym zakresie wartości, ale występują również dni z bardzo wysoką średnią glikemią. Oznacza to, że modele muszą radzić sobie nie tylko z typowymi przypadkami, lecz także z bardziej skrajnymi wartościami.

Rozkład zmiennej celu jest podobny do rozkładu bieżącej średniej glikemii. Jest to oczekiwane, ponieważ model przewiduje wartość tego samego typu, ale przesuniętą o jeden dzień pomiarowy.

Średnie wartości glikemii różnią się pomiędzy pacjentami. Wskazuje to na indywidualny charakter danych medycznych i uzasadnia wykorzystanie cech historycznych, takich jak poprzednie pomiary danego pacjenta.

Wykresy przebiegów czasowych pokazują, że poziom glikemii u pacjentów może zmieniać się dynamicznie. U niektórych osób wartości są stosunkowo stabilne, natomiast u innych widoczne są duże wahania. Jest to jeden z powodów, dla których predykcja glikemii jest trudnym problemem.




Figure 1: Rozkład średniej dziennej glikemii.




Figure 2: Rozkład zmiennej celu.




Figure 3: Średnia glikemia według pacjentów.




Figure 4: Przebieg średniej glikemii dla przykładowych pacjentów.

6 Metodologia badania

Dane podzielono na zbiory treningowy, walidacyjny i testowy osobno dla każdego pacjenta, z zachowaniem kolejności czasowej. Pierwsze 60% obserwacji każdego pacjenta wykorzystano do uczenia modeli, kolejne 20% do walidacji i doboru parametrów, a ostatnie 20% do końcowej oceny jakości predykcji.

Table 4: Liczebność zbiorów treningowego, walidacyjnego i testowego.

set	n
test	783
train	2244
validation	762

Braki danych w zmiennych objaśniających uzupełniono medianami obliczonymi wyłącznie na zbiorze treningowym. Dzięki temu dane walidacyjne i testowe nie wpływały na etap przygotowania modelu.

Do oceny modeli wykorzystano trzy metryki regresyjne:

- **RMSE** - pierwiastek ze średniego błędu kwadratowego,
- **MAE** - średni błąd bezwzględny,
- **R2** - współczynnik determinacji.

Niższe wartości RMSE i MAE oznaczają lepszą jakość predykcji. Wyższa wartość R2 oznacza lepsze dopasowanie modelu do danych.

7 Opis zastosowanych metod

7.1 CART

CART jest pojedynczym drzewem decyzyjnym. Model dzieli dane na coraz bardziej jednorodne grupy na podstawie wartości zmiennych objaśniających. Zaletą tej metody jest łatwa interpretacja, ponieważ można prześledzić reguły podziału. Wadą jest podatność na przeuczenie i ograniczona stabilność predykcji.

7.2 Random Forest

Random Forest jest metodą zespołową, która buduje wiele drzew decyzyjnych i uśrednia ich predykcje. Każde drzewo uczone jest na nieco innym fragmencie danych i z wykorzystaniem losowego podzbioru zmiennych. Dzięki temu model jest zwykle bardziej stabilny i mniej podatny na przeuczenie niż pojedyncze drzewo.

7.3 XGBoost

XGBoost jest metodą gradient boosting. Model buduje kolejne drzewa sekwencyjnie, a każde następne drzewo stara się poprawić błędy poprzednich. Jest to metoda często osiągająca wysoką skuteczność predykcyjną, ale mniej intuicyjna interpretacyjnie i bardziej zależna od doboru parametrów.

Drzewo decyzyjne CART




Figure 5: Uproszczone drzewo decyzyjne CART.

8 Wyniki eksperymentów

W przypadku modelu CART najważniejszym pierwszym podziałem była średnia krocząca glikemii z ostatnich wartości. Oznacza to, że pojedyncze drzewo opierało predykcję głównie na historii poziomu glukozy.

Table 5: Wyniki strojenia parametrów Random Forest na zbiorze walidacyjnym.

RMSE	MAE	R2	mtry	min.node.size
45.187	33.773	0.290	4	5
45.220	33.892	0.288	7	5
45.322	33.895	0.285	7	10
45.351	34.041	0.285	4	10

Table 6: Wyniki strojenia parametrów XGBoost na zbiorze walidacyjnym.

max_depth	eta	nrounds	validation_RMSE
3	0.10	100	45.719
3	0.05	100	45.763
2	0.10	100	45.920
2	0.05	100	46.233

Table 7: Porównanie jakości modeli na zbiorze testowym.

model	RMSE	MAE	R2
Random Forest	47.049	35.055	0.353
XGBoost	48.709	36.758	0.303
CART	53.252	40.325	0.166

Najlepszy wynik uzyskał model **Random Forest**, który osiągnął najniższe wartości RMSE i MAE oraz najwyższą wartość R2. Drugie miejsce zajął **XGBoost**, natomiast najslabszy wynik uzyskał pojedynczy model **CART**.

Oznacza to, że modele zespołowe poprawiły jakość predykcji względem pojedynczego drzewa decyzyjnego. Random Forest okazał się w tym zadaniu bardziej skuteczny niż XGBoost, mimo że XGBoost jest modelem bardziej zaawansowanym.




Figure 6: Porównanie jakości modeli na podstawie RMSE, MAE i R2.

Na wykresie widać, że Random Forest ma najniższe błędy RMSE i MAE. Różnica między Random Forest a XGBoost nie jest bardzo duża, ale oba modele wyraźnie przewyższają CART pod względem jakości predykcji.

9 Analiza predykcji i błędów

Wykres wartości rzeczywistych i przewidywanych pokazuje, że modele dobrze odtwarzają ogólny poziom glikemii, ale mają problem z wartościami skrajnymi. Jest to typowe dla modeli regresyjnych w danych medycznych, gdzie pojedyncze nietypowe obserwacje mogą zależeć od czynników niewystępujących w zbiorze danych.




Figure 7: Porównanie wartości rzeczywistych i przewidywanych.

Na wykresie dla modelu CART widoczne są poziome pasy predykcji. Nie jest to błąd, lecz cecha pojedynczego drzewa decyzyjnego. Model CART przypisuje obserwacje do końcowych liści drzewa, a każdemu liściowi odpowiada jedna stała wartość przewidywana. Z tego powodu model generuje ograniczoną liczbę możliwych predykcji i jest mniej elastyczny niż Random Forest oraz XGBoost. Wykres potwierdza, że CART słabiej odwzorowuje ciągłą zmienność glikemii.

Table 8: Podstawowa analiza błędów predykcji.

model	sredni_blad	sredni_blad_bezwzględny	maksymalny_blad_bezwzględny
CART	1.815	40.325	223.695
Random_Forest	1.983	35.055	225.304
XGBoost	1.882	36.758	223.907




Table 9: Dziesięć najważniejszych zmiennych dla każdego modelu.

feature	importance	model
rolling_glucose_3	1130199.890	CART
glucose_mean	602735.865	CART
glucose_lag1	576870.185	CART
glucose_lag2	549398.633	CART
glucose_max	514835.455	CART
glucose_min	335427.576	CART
regular_insulin_total	153615.451	CART
n_records	93876.109	CART
insulin_total	91250.204	CART
insulin_lag1	78777.154	CART
rolling_glucose_3	1169793.214	Random Forest
glucose_mean	802006.933	Random Forest
glucose_lag1	757774.200	Random Forest
glucose_max	687864.241	Random Forest
glucose_lag2	617986.584	Random Forest
glucose_sd	532584.287	Random Forest
glucose_min	506037.351	Random Forest
insulin_lag1	499441.751	Random Forest
regular_insulin_total	498861.536	Random Forest
insulin_total	469294.641	Random Forest
rolling_glucose_3	0.358	XGBoost
regular_insulin_total	0.064	XGBoost
insulin_lag1	0.061	XGBoost
glucose_max	0.060	XGBoost
insulin_total	0.059	XGBoost
glucose_mean	0.056	XGBoost
glucose_min	0.048	XGBoost
weekday	0.046	XGBoost
glucose_sd	0.043	XGBoost
glucose_lag2	0.041	XGBoost

Analiza ważności zmiennych pokazuje, że największe znaczenie miały wcześniejsze wartości glikemii. Szczególnie istotna była zmienna `rolling_glucose_3`, czyli średnia z bieżącej i poprzednich wartości glikemii. Duże znaczenie miały również `glucose_mean`, `glucose_lag1`, `glucose_lag2`, `glucose_max` oraz `glucose_min`.

Jest to zgodne z intuicją, ponieważ poziom glukozy w kolejnym dniu powinien być silnie powiązany z wcześniejszymi pomiarami. W modelach pojawiły się także zmienne dotyczące insuliny, takie jak `insulin_total`, `regular_insulin_total` i `insulin_lag1`, co sugeruje, że informacje o leczeniu również wspierały predykcję.

11 Wnioski

Celem projektu było sprawdzenie, czy zaawansowane metody drzewiaste poprawiają przewidywanie zmian stanu zdrowia pacjentów z cukrzycą. Na podstawie przeprowadzonych eksperymentów można stwierdzić, że modele zespołowe rzeczywiście osiągnęły lepsze wyniki niż pojedyncze drzewo CART.

Najlepszy wynik uzyskał **Random Forest**, który miał najniższe wartości RMSE i MAE oraz najwyższe R2. Oznacza to, że w tym zadaniu najlepiej przewidywał średnią glikemię pacjenta w kolejnym dostępnym




Figure 9: Najważniejsze zmienne w porównywanych modelach.

dniu pomiarowym. **XGBoost** również poprawił wynik względem CART, ale był słabszy od Random Forest. Najsłabiej wypadł **CART**, co sugeruje, że pojedyncze drzewo było zbyt prostym modelem dla analizowanego problemu.

Najważniejszymi predyktorami okazały się wcześniejsze wartości glikemii, zwłaszcza średnia krocząca oraz wartości opóźnione. Wynik ten jest logiczny, ponieważ przyszły poziom glukozy zależy w dużej mierze od wcześniejszego przebiegu pomiarów. Znaczenie miały również zmienne związane z insuliną, co wskazuje, że modele korzystały także z informacji o leczeniu pacjenta.

Warto jednak zauważyć, że uzyskane wartości R^2 nie są bardzo wysokie. Oznacza to, że przewidywanie glikemii jest trudnym problemem, a dostępne dane nie opisują wszystkich czynników wpływających na stan pacjenta. Na poziom glukozy mogą wpływać m.in. dokładny skład posiłków, stres, choroby współistniejące, sen czy szczegóły aktywności fizycznej, których w zbiorze danych nie ma lub są zapisane w uproszczony sposób.

Ograniczeniem badania jest także uproszczona definicja progresji cukrzycy. W projekcie potraktowano ją jako zmianę średniej glikemii w kolejnym dniu, a nie jako długoterminowe pogorszenie stanu zdrowia. Mimo tego analiza pozwoliła porównać trzy metody drzewiaste i pokazała, że w tym przypadku modele zespołowe, szczególnie Random Forest, są skuteczniejsze od pojedynczego drzewa decyzyjnego.